

UMA PROPOSTA PARA APRENDIZADO ONLINE VIA REDES NEURAIAS
SEM PESO PARA SELEÇÃO DE FEIXES DE SISTEMAS 5G/6G EM
CENÁRIOS VEICULARES.

Joanna Carolina Manjarres Meneses

Exame de Qualificação de Doutorado
apresentado ao Programa de Pós-graduação
em Engenharia de Sistemas e Computação,
COPPE, da Universidade Federal do Rio de
Janeiro, como parte dos requisitos necessários
à obtenção do título de Doutor em Engenharia
de Sistemas e Computação.

Orientadores: Jose Ferreria de Rezende
Douglas Oliveira de Cardoso

Rio de Janeiro
Fevereiro de 2025

UMA PROPOSTA PARA APRENDIZADO ONLINE VIA REDES NEURAIIS
SEM PESO PARA SELEÇÃO DE FEIXES DE SISTEMAS 5G/6G EM
CENÁRIOS VEICULARES.

Joanna Carolina Manjarres Meneses

EXAME DE QUALIFICAÇÃO SUBMETIDO AO CORPO DOCENTE DO
INSTITUTO ALBERTO LUIZ COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA
DE ENGENHARIA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO
GRAU DE DOUTOR EM CIÊNCIAS EM ENGENHARIA DE SISTEMAS E
COMPUTAÇÃO.

Orientadores: Jose Ferreria de Rezende
Douglas Oliveira de Cardoso

Aprovada por: Prof. Priscila Machado Vieira Lima
Prof. Felipe Augusto Pereira de Figueiredo

RIO DE JANEIRO, RJ – BRASIL
FEVEREIRO DE 2025

Resumo do Exame de Qualificação apresentado à COPPE/UFRJ como parte dos requisitos necessários para a obtenção do grau de Doutor em Ciências (D.Sc.)

UMA PROPOSTA PARA APRENDIZADO ONLINE VIA REDES NEURAIIS
SEM PESO PARA SELEÇÃO DE FEIXES DE SISTEMAS 5G/6G EM
CENÁRIOS VEICULARES.

Joanna Carolina Manjarres Meneses

Fevereiro/2025

Orientadores: Jose Ferreria de Rezende

Douglas Oliveira de Cardoso

Programa: Engenharia de Sistemas e Computação

Abstract of Qualifying Exam presented to COPPE/UFRJ as a partial fulfillment of the requirements for the degree of Doctor of Science (D.Sc.)

A PROPOSAL FOR ONLINE LEARNING VIA WEIGHTLESS NEURAL NETWORKS FOR BEAM SELECTION OF 5G/6G SYSTEMS IN VEHICULAR SCENARIOS.

Joanna Carolina Manjarres Meneses

February/2025

Advisors: Jose Ferreria de Rezende

Douglas Oliveira de Cardoso

Department: Systems Engineering and Computer Science

Sumário

Lista de Figuras	vii
Lista de Tabelas	x
Lista de Abreviaturas	xi
1 Introdução	1
2 Fundamentação teórica	6
2.1 Comunicação em redes celulares 5G-6G	6
2.1.1 Transmissão Multi-antena	8
2.1.2 Comunicações MIMO	9
2.2 Redes Neurais sem Peso	15
2.2.1 Treinamento da rede WiSARD	15
2.2.2 Classificação da rede WiSARD	16
2.2.3 Mecanismo de Bleaching na Rede WiSARD	17
2.2.4 Características e Benefícios da WiSARD	19
2.3 Estratégias para seleção de dados em aprendizado <i>on-line</i>	24
3 Revisão Bibliográfica	27
4 Análises de dados	36
4.1 Análise do Dataset	36
4.2 Pré-processamento dos dados	40
4.2.1 Coordenadas	40
4.2.2 LiDAR	42
4.2.3 Pós-processamento dos rótulos	44
4.3 Descrição dos métodos de <i>baseline</i>	45
5 Metodologia proposta	47
5.1 Proposta para avaliação	48
5.1.1 Abordagem de janela fixa	49
5.1.2 Abordagem de janela incremental	49

5.1.3	Abordagem de janela deslizante	49
5.2	Indicadores de desempenho	51
6	Resultados parciais e discussões	53
6.1	Desempenho da rede WiSARD	53
6.2	Comparação convencional dos modelos	54
6.3	Comparação dos modelos usando a metodologia proposta	57
6.3.1	Janela fixa	57
6.3.2	Janela deslizante	59
6.3.3	Janela incremental	61
6.3.4	Janela deslizante saltitante	62
6.3.5	Análise de desempenho da metodologia proposta na rede Wi- SARD	63
7	Conclusões	65
7.1	Conclusões parciais	65
7.2	Artigos publicados	66
8	Proposta de tese	67
8.1	Modelagem e simulação	68
8.2	Avaliação experimental	68
8.3	Incorporação de técnicas RIS	69
	Referências Bibliográficas	71
A	Antenas Uniformes Planares (UPA)	79
B	Antenas Uniformes Circulares (UCA)	81
C	Ajuste de Hiper-parâmetros da rede WiSARD usando coordenadas	83
D	Análise do <i>dataset</i> Raymobtime	85

Lista de Figuras

1.1	Velocidades e Tecnologias nas Gerações de Redes Móveis	2
2.1	Protótipo de um <i>array</i> de antena 8X8 usado em 28 GHz. Imagem tomada de (ZAIDI <i>et al.</i> , 2018)	7
2.2	Arquitetura de <i>beamforming</i> analógico. Esta arquitetura gera apenas um feixe devido à única cadeia de RF.	9
2.3	Arquitetura de <i>beamforming</i> digital. Múltiplos feixes são obtidos por meio de formadores de feixes digitais, mas ao custo de múltiplas cadeias de	9
2.4	Arquitetura de <i>beamforming</i> híbrido. Gera múltiplos feixes com menos cadeias de RF por meio de configurações como: submatriz conectada, totalmente conectada, antena seletiva esparsa e arquiteturas de banda larga	10
2.5	Propagação multi-caminho num sistema MIMO; a linha azul representa sinais recebidas por caminhos diretos e a linha vermelha representa sinais por caminhos refletidos	11
2.6	Representação do sinal transmitido num enlace LoS	12
2.7	Exemplo de um discriminador da letra E na fase de treinamento . . .	17
2.8	Exemplo de classificação de um número usando a rede WiSARD . . .	17
2.9	Exemplo do uso do mecanismo <i>bleaching</i>	19
2.10	Classificação de técnicas usadas no aprendizado <i>on-line</i>	25
4.1	Diagrama de blocos do <i>dataset</i> Raymobtime tomado de LASSE (2020)	37
4.2	Representação do cenário de comunicação do dataset	38
4.3	Média das amostras a cada 100 episódios	39
4.4	Exemplo de pré-processamento de três valores de coordenadas na posição x . A primeira coordenada na posição mínima, a segunda na posição máxima e a terceira numa posição intermediária.	41
4.5	Pré-processamento dos dados LiDAR. Lado esquerdo, receptor em 3D. Lado direito cenário completo quantizado	42

4.6	Pré-processamento dos dados LiDAR. Posição do receptor e cenário completo em 2D	42
4.7	Avaliação de desempenho dos dados lidar 2D em função do endereçamento das memórias RAM	43
4.8	Avaliação de desempenho do modelo WiSARD usando a técnica de limite de variância em dados LiDAR 2D	43
4.9	Distribuição dos índices dos feixes.	45
4.10	Modelo de rede neural usado em SALEHI <i>et al.</i> (2022) para entrada LiDAR	45
4.11	Modelo de rede neural usado em RUSECKAS <i>et al.</i> (2021) para entrada LiDAR	46
5.1	Diagrama de sequência ideal entre o transmissor e o receptor	48
5.2	Representação da janela fixa	49
5.3	Representação da janela incremental	50
5.4	Representação da janela deslizante	50
6.1	Comparação de desempenho da rede WiSARD, com diferentes entradas e tipos de comunicação	53
6.2	Diagrama de sequencia de uma avaliação tradicional	54
6.3	Comparação de desempenho de acurácia entre o modelo proposto WISARD e as técnicas de aprendizado de maquina propostas pelos autores SALEHI <i>et al.</i> (2022), e RUSECKAS <i>et al.</i> (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).	55
6.4	Comparação de desempenho de <i>throughput ratio</i> entre o modelo proposto WISARD e as técnicas de aprendizado de maquina propostas pelos autores SALEHI <i>et al.</i> (2022), e RUSECKAS <i>et al.</i> (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).	55
6.5	Comparação dos tempos de treinamento entre o modelo proposto e as técnicas de aprendizado de maquina da literatura dos autores SALEHI <i>et al.</i> (2022), e RUSECKAS <i>et al.</i> (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).	56
6.6	Desempenho da rede WiSARD em tempos de treinamento usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).	56
6.7	Abordagem de Janela fixa. Comparação de desempenho top-k com dados LiDAR entre as técnicas avaliadas	58

6.8	Abordagem janela fixa. Comparação de desempenho da rede WiSARD com entradas coordenadas, LiDAR, e coordenadas + LiDAR. .	59
6.9	Desempenho da rede WiSARD variando os tamanhos das janelas usando coordenadas	60
6.10	Comparação dos tempos de treinamento para diferentes tamanhos de janelas usando uma abordagem de janela incremental e coordenadas como entrada	61
6.11	Abordagem Janela incremental. Desempenho da rede WiSARD com entradas unimodais e multimodais.	62
6.12	Comparação de desempenho da rede WiSARD nas abordagens propostas de aprendizado <i>on-line</i> usando os dados das coordenadas.	63
6.13	Comparação dos tempos de treinamento da rede WiSARD nas abordagens propostas de aprendizado <i>on-line</i> usando os dados das coordenadas	64
C.1	Mapa de calor do desempenho da acurácia com entradas de coordenadas da rede WiSARD	84
C.2	Desempenho da rede WiSARD variando o endereçamento da memória com entradas de coordenadas e resolução igual 8	84
D.1	Feixes selecionados em cada canal de comunicação para todos os receptores	86
D.2	Segregação dos feixes selecionados entre o Tx e o RX	87
D.3	Seleção de feixes no Transmissor	87
D.4	Seleção de feixes no Receptor	88
D.5	Seleção de feixes no Receptor	89

Lista de Tabelas

3.1	Comparação de trabalhos relacionados	30
3.2	Comparação dos resultados alcançados pelos trabalhos da revisão bibliográfica	34
4.1	Descrição dos sub-conjuntos do <i>dataset</i> Raymobtime	37
4.2	Estatísticas dos dataset S008 e S009	38
4.3	Parâmetros usados pelos autores do <i>baseline</i> B. Salehi SALEHI <i>et al.</i> (2022) e J. Ruseckas RUSECKAS <i>et al.</i> (2021) no modelo LiDAR	46
6.1	Comparação de desempenho da acurácia top-1 dos modelos proposto por J. Ruseckas RUSECKAS <i>et al.</i> (2021), B. Salehi SALEHI <i>et al.</i> (2022) e a proposta da rede WiSARD, para a abordagem de janela fixa.	57
6.2	Comparação de estatísticas de tempo de treinamento para janela fixa entre o modelo WiSARD e os modelo de <i>baseline</i>	58
6.3	Comparação de desempenho top-1 dos modelos J. Ruseckas RUSECKAS <i>et al.</i> (2021), B. Salehi SALEHI <i>et al.</i> (2022) e modelo proposto WiSARD, para uma abordagem de janela deslizante, com tamanho de janela = 1000 episódio para treinamento.	60
6.4	Comparacao de desempenho acuracia top-1 dos modelos J. Ruseckas RUSECKAS <i>et al.</i> (2021), B. Salehi SALEHI <i>et al.</i> (2022) e WiSARD, usando na abordagem de janela incremental.	61
6.5	Desempenho do modelo proposto por SALEHI <i>et al.</i> (2022) usando dados LiDAR na abordagem janela saltitante deslizante.	62
C.1	Impacto da resolução do termômetro sobre o tamanho da entrada	83

Lista de Abreviaturas

1G	Primeira Geração de rede móvel sem fio	6
2G	Segunda Geração de rede móvel sem fio	6
3G	Terceira Geração de rede móvel sem fio	6
5G	Quinta Geração de rede móvel sem fio	6
ADC	conversor analógico-digital	8
AoA	Angle of Arrival	10
AoD	Angle of Departure	10
DAC	conversor digital-analógico	8
DNN	Deep Neural Network	3
DTF	Discrete Fourier transform	14
GNS	Goal Seeking Neuron	15
GRAM	Generalization RAM	15
LoS	Line of Signal	vii, 12
LTE	Long Term Evolution	1
MIMO	Multiple Input Multiple Output	6
ML	Machine Learning	15
mm-Wave	ondas milimétricas	7
MRC	maximal ratio combining	10
NLoS	Non line of sight	13

RF	Radio Frequência	vii, 9
RNSP	Redes Neurais Sem Peso	15
RNSP	Redes Neurais sem Peso	3
UCA	Uniform Circular Array	12
ULA	Uniform Linear Array	12
UPA	Uniform Planar Array	12
VG-RAM	Virtual Generalization RAM	15
WiSARD	Wilkes, Stonham and Aleksander Recognition Device	6
WiSARD	Wilkie, Stonham, and Aleksander's Recognition Device	4

Capítulo 1

Introdução

O setor das telecomunicações móveis tem experimentado avanços revolucionários em poucas décadas, com a introdução de quatro gerações de tecnologias desde a década de 1980. Essa evolução não se limitou ao aumento das velocidades de transmissão, mas também foi impulsionada por avanços significativos em técnicas e tecnologias destinadas a explorar de forma mais eficiente o espectro eletromagnético. Tecnologias como multiplexação, digitalização de sinais e agora a introdução de ondas milimétricas mostram a dinâmica do setor.

A primeira geração (1G) marcou o início das comunicações móveis analógicas, permitindo chamadas de voz básicas, de baixa qualidade. Na década de 1990, a segunda geração (2G) trouxe a digitalização, aumentando a qualidade de voz, mensagens de texto (SMS) e maior eficiência espectral. Nos anos 2000 a terceira geração (3G), marcou a integração de dados e voz, introduzindo serviços como navegação na internet e streaming de áudio e vídeo, com taxas de dados significativamente mais altas. A quarta geração (4G), lançada a partir de 2010, transformou as comunicações móveis ao introduzir redes baseadas em IP e a tecnologia LTE , oferecendo velocidades de banda larga móvel comparáveis às conexões fixas. Foram possíveis aplicações mais exigentes, como videochamadas em alta definição e serviços de computação em nuvem. Na figura 1.1, é apresentada a evolução das velocidades e tecnologias usadas da 1G até a 4G.

Enquanto o 5G consolidou avanços em latência e densidade de dispositivos, o 6G busca integrar funcionalidades inovadoras que vão além da comunicação tradicional. A quinta geração (5G) está redefinindo o setor ao trazer melhorias substanciais em capacidade, latência baixa latência e suporte para uma alta densidade de dispositivos conectados. Essa tecnologia não apenas oferece maior eficiência espectral, mas também introduz conceitos inovadores como *network slicing*, integração de comunicações com computação em borda (*edge computing*) e suporte para aplicações críticas, como veículos autônomos, fábricas inteligentes e telemedicina.

As pesquisas sobre a sexta geração (6G) têm como objetivo não apenas aumen-




Figura 1.1: Velocidades e Tecnologias nas Gerações de Redes Móveis

tar a eficiência espectral, mas também integrar funcionalidades como sensoriamento ambiental, conectividade holográfica e comunicações em ondas terahertz. Diferentemente das gerações anteriores, o 6G busca combinar comunicação com tecnologias emergentes, permitindo, por exemplo, o uso simultâneo de redes para posicionamento e mapeamento urbano. Essas inovações têm o potencial de transformar aplicações críticas, como veículos autônomos em cenários urbanos complexos, onde a localização precisa é tão importante quanto a comunicação.

De acordo com *white paper* anual apresentado pela CISCO (2020), os autores tinham previsto que em 2023 mais de 70% da população mundial (aproximadamente 5,7 bilhões de pessoas) tivesse conectividade móvel, e os dados móveis global alcançasse 77 exabytes por mês em 2022, um aumento em comparação com 19 exabytes por mês em 2017. O que corresponde a um crescimento anual composto (CAGR) de aproximadamente 46% entre 2017 e 2022. No Brasil, o número de dispositivos conectados chegaria a aproximadamente 678 milhões em 2023. Essas estatísticas indicam um crescimento contínuo e significativo no tráfego de dados móveis, impulsionado por fatores como a adoção de tecnologias emergentes, popularização de smartphones, o crescimento de aplicações de vídeo em alta definição e a expansão da Internet das Coisas (IoT).

Assim, o espectro de frequências se torna um recurso disputado e o uso frequências de ondas milimétricas (mmWave), tipicamente na faixa de 24 GHz a 300 GHz, é uma estratégia que permite atender a estas demandas. Elas oferecem maior largura de banda, permitindo maiores taxas de transmissão. No entanto, devido a suas características físicas é um campo desafiador. Possuem uma propagação limitada, pois a difração não é mais o fenômeno dominante, além de aumentar a perda de

penetração em edifícios e ambientes confinados.

Contudo, tecnologias como MIMO e formação de feixes (*beamforming*) visam melhorar a eficiência do sinal nestas frequências. A conformação de feixe, a partir de arranjos que possuem um grande número de antenas, aumenta a diretividade dos feixes gerados por estes sistemas, possibilitando a adaptação do padrão de irradiação do conjunto de elementos de transmissão e recepção, com o objetivo de estabelecer um enlace de comunicação estável.

Um método comum de uso dos sistemas MIMO é através da estimação do canal. Sinais pilotos são enviados periodicamente, permitindo que tanto o transmissor quanto o receptor calculem vetores de *beamforming* que otimizam a comunicação. Apesar de permitir que o melhor feixe seja utilizado a cada instante, essa estratégia exige um processamento complexo por parte dos dispositivos e gera um grande *overhead* devido à troca de informações de estimação do canal.

Uma outra forma de uso dos sistemas MIMO é através da construção prévia de vetores de *beamforming*, tanto para o transmissor quanto para o receptor, denominado de *codebook*. Estes vetores que compõem o *codebook* podem ser calculados de acordo com o ambiente no qual serão utilizados, de tal forma que o conjunto de feixes disponíveis cubra toda uma região do espaço. Neste caso, cada par transmissor-receptor deve realizar um processo de varredura entre todos os feixes para encontrar o melhor par de feixes a ser utilizado. Este método tem como vantagem o baixo *overhead* no canal, mas dependendo do número de feixes do *codebook*, ele pode se tornar bastante oneroso, principalmente quando existe mobilidade por partes dos usuários.

Com o intuito de diminuir a complexidade e, com isso o tempo de seleção dos melhores vetores, técnicas de aprendizado de máquina e informações de contexto têm sido incorporados como aliados nesta tarefa.

Na última década, redes neurais profundas (DNN) têm-se destacado com grandes avanços em tarefas de reconhecimento e classificação de objetos, atingindo alta precisão (RUSSAKOVSKY *et al.*, 2015). No entanto, a implementação desses modelos é cara, tanto em termos de memória quanto de computação, como mostrado por SUSSKIND *et al.* (2022), no estudo que compara o número de pesos e operações de multiplicação-acumulação (MACs) de redes como ResNet e OpenPose, entre outras. Em cenários onde os modelos devem ser executados em dispositivos pequenos e com restrição de energia, a implementação dessas redes se torna impraticável.

Para o desenvolvimento deste trabalho, foi usada como técnica de aprendizado de máquina as redes neurais sem peso (RNSPs). A funcionalidade deste tipo de rede difere das redes neurais convencionais, pois o funcionamento de um neurônio é modificado por mudanças no conteúdo dos nós RAM, em vez de ajustes em pesos sinápticos.

As RNSPs imitam a função excitatória/inibitória das árvores dendríticas dos

neurônios biológicos. Elas mapeiam sinais de inibição ou excitação de um neurônio por meio de uma representação booleana (ALEKSANDER *et al.*, 2009). Os neurônios biológicos são representados por nós de memórias RAM, que possuem entradas e saídas binárias. Assim, as RNSP são compostas por memórias RAM, que usam tabelas de consulta para representar funções booleanas de suas entradas como uma tabela verdade. Essas entradas são concatenadas para formar um endereço e produzir a entrada de tabela correspondente como sua resposta (SUSSKIND *et al.*, 2022).

Entre os diversos tipos de RNSP, foi utilizada neste trabalho a rede WiSARD . Originalmente concebida como um dispositivo de reconhecimento de padrões para processamento de imagens, a WiSARD utiliza um esquema de codificação binária para transformar dados multivariáveis no domínio dos números reais em padrões binários, que são usados como entrada do modelo. Uma vez que os dados são binarizados, eles são pseudoaleatoriamente escolhidos para formar n-tuplas, que, por sua vez, são usadas para treinar (escrever) ou classificar (ler) nas memórias RAM.

Em suma, ao longo deste trabalho, será apresentada a viabilidade da utilização das redes RNSP - WiSARD para a seleção de feixe de um sistema MIMO. Para isto, no capítulo 2 uma fundamentação teórica é apresentada, são introduzidos conceitos como *beamforming* e seus tipos, uma ideia geral da conformação da matriz do canal em sistemas MIMO com o intuito de evidenciar a importância de uma ótima escolha do feixe. Neste capítulo também é introduzido o método de aprendizado de máquina escolhido, a RNSP WiSARD, nele é mostrado seu processo de treinamento e classificação, assim como vantagens, desvantagens e aplicações.

Afim de conhecer como a seleção de feixe tem sido abordada na comunidade científica, o capítulo 3 apresenta a revisão bibliográfica dos trabalhos mais atuais onde são usadas técnicas de aprendizado de máquina para a seleção de feixe.

O capítulo 4 descreve o *dataset* utilizado, o Raymobtime, que recria um cenário de redes veiculares usando altas frequências. Também é mostrado como foi abordado o pré-processamento dos dados oferecidos pelo *dataset* com o intuito de usar a rede neural WiSARD assim como o ajuste do modelo. Finalmente, este capítulo também apresenta os métodos escolhidos como *baseline* de comparação.

O capítulo 5 aborda a metodologia proposta, uma abordagem online para seleção de feixe, assim como as métricas escolhidas para avaliação.

No capítulo 6, são apresentados os resultados parciais: inicialmente é mostrado o desempenho da rede WiSARD nas condições de LoS, NLoS, e LoS+NLoS; em seguida, uma comparação do desempenho da WiSARD com as técnicas de aprendizado de máquina de *baseline*; e finalmente, a metodologia proposta é avaliada para o aprendizado *on-line* no problema de seleção de feixe.

O capítulo 7, apresenta as conclusões parciais do trabalho desenvolvido até o momento, assim como também as publicações realizadas.

E finalmente, no capítulo 8, são propostas possíveis abordagens as quais visam dar continuidade ao trabalho desenvolvido até o momento.

Capítulo 2

Fundamentação teórica

Este capítulo apresenta os conceitos fundamentais relacionados à seleção de feixe em sistemas de comunicação celular utilizando ondas milimétricas. Serão abordadas as técnicas MIMO e arquiteturas de formação de feixe, destacando o impacto da geometria das antenas na qualidade do sinal recebido. A formação de feixe, essencial em sistemas com múltiplas antenas, otimiza a direção do sinal, aumentando a potência no receptor e minimizando interferências.

Além disso, será introduzida a técnica de aprendizado de máquina proposta para seleção de feixe: a rede neural sem peso. A WiSARD se destaca pela eficiência em tempo real e baixo custo, sendo uma alternativa inovadora para sistemas de comunicação móvel. O funcionamento, as vantagens e suas aplicações em diferentes cenários serão discutidos.

2.1 Comunicação em redes celulares 5G-6G

Nas primeiras gerações de sistemas de comunicação celular, como 1G e 2G, as frequências utilizadas estavam na faixa de 800 a 900 MHz. Para a terceira geração, 3G (IMT-2000), a frequência foi em torno de 2 GHz, mas, com o aumento da demanda por serviços, novas bandas foram adicionadas, abrangendo atualmente de 450 MHz a cerca de 6 GHz.

Entretanto, o comportamento físico das ondas varia conforme a frequência utilizada. Em frequências baixas, a propagação das ondas alcança maiores distâncias, o que as torna adequadas para sistemas celulares em ambientes urbanos, suburbanos e rurais. Por outro lado, ondas de altas frequências são associadas a maior atenuação de canal, limitando a cobertura da rede, sendo, portanto, mais eficazes em ambientes densos.

A chegada da quinta geração (5G) trouxe requisitos mais elevados, como altas taxas de transferência e maior capacidade em cenários densos. Embora muitas implementações iniciais tenham sido feitas utilizando bandas abaixo de 6 GHz, o

uso de frequências mais altas, acima de 24 ou 60 GHz, tem sido considerado como um complemento. Essas bandas oferecem acesso a um maior espectro, reduzindo a carga sobre as frequências mais baixas. Esse tipo de faixa é conhecido como ondas milimétricas (mm-Wave) , devido ao comprimento de onda reduzido.

As ondas milimétricas enfrentam maior perda de propagação, o que exige feixes focados para compensar essa atenuação. A escolha adequada do feixe afeta diretamente o desempenho do sistema. A seleção de feixe é uma técnica crucial em sistemas de comunicação sem fio modernos, referindo-se ao processo de escolher o melhor feixe de transmissão e/ou recepção entre um conjunto de feixes pré-definidos.

Um dos componentes chave desses sistemas é o uso de múltiplas antenas, pois as altas frequências impactam diretamente o tamanho físico da antena. Como relatado por (DAHLMAN *et al.*, 2020), um aumento de dez vezes na frequência da portadora resulta em uma redução de dez vezes no comprimento de onda, correspondendo a uma diminuição de dez vezes nas dimensões físicas das antenas do receptor, ou a um fator de redução de 100 na área física da antena. Isso se traduz em uma perda de 20 dB no sinal captado pela antena.

Para compensar essa redução, são utilizados painéis de antenas compostos por um grande número de pequenos elementos de antena, nos quais a direção do sinal pode ser ajustada configurando separadamente a fase, o ganho, e a potência dos sinais de cada elemento. Na Figura 2.1, é mostrado um exemplo de um sistema compacto de antena ativa para ondas milimétricas.




Figura 2.1: Protótipo de um *array* de antena 8X8 usado em 28 GHz. Imagem tomada de (ZAIDI *et al.*, 2018)

2.1.1 Transmissão Multi-antena

A propagação multi-caminho, característica dos sistemas celulares, resulta em múltiplos raios de sinal que causam desvanecimento rápido em comunicações sem fio.

O uso de múltiplas antenas tanto no transmissor quanto no receptor melhora a capacidade, cobertura, taxa de dados e confiabilidade da rede. Essa técnica oferece diversidade contra desvanecimento e possibilita o aumento da relação sinal-ruído (SNR), permitindo a combinação construtiva dos sinais transmitidos.

Ajustando a fase e amplitude de cada elemento da antena, é possível modificar o padrão de radiação de um *array* de antenas, direcionando o sinal para aumentar a potência na direção desejada (*beamforming*). Isso pode melhorar as taxas de dados, reduzir interferências e aumentar o alcance do sinal.

Além disso, a presença de múltiplas antenas viabiliza a multiplexação espacial, permitindo a transmissão de múltiplos fluxos simultâneos usando os mesmos recursos de tempo e frequência. A escolha da arquitetura para formação de feixe (banda base, intermediária ou híbrida) e o tipo de implementação (analógica, digital ou híbrida) são fatores essenciais para essa técnica (AGIWAL *et al.*, 2016; MOHAMED *et al.*, 2021).

- **Formação de feixe analógico**

Na formação de feixe analógico, o mesmo sinal é transmitido por cada antena, mas com fases ajustadas de maneira independente, direcionando o feixe na direção desejada. O processamento é realizado com deslocadores de fase analógicos em cada elemento da antena.

Esse tipo de processamento, geralmente realizado por portadora, exige que os feixes para dispositivos localizados em direções diferentes sejam temporariamente separados. No receptor, o processamento multi-antena ocorre antes da conversão analógico-digital, limitando a formação de feixes a uma direção por vez. Isso reduz a capacidade de multiplexação espacial, já que a recepção de múltiplas direções ocorre em momentos distintos (ZAIDI *et al.*, 2018).

- **Formação de feixe digital**

Em uma arquitetura digital, cada elemento de antena possui sua própria cadeia de RF e conversores ADC e DAC. Isso permite maior flexibilidade no processamento multi-antena, com ajustes tanto na fase quanto na potência de cada elemento.

Além disso, o processamento independente de múltiplas antenas possibilita a transmissão simultânea de sinais de diferentes dispositivos, localizados em direções distintas, dentro da mesma portadora (DAHLMAN *et al.*, 2020). No




Figura 2.2: Arquitetura de *beamforming* analógico. Esta arquitetura gera apenas um feixe devido à única cadeia de RF.

receptor, é possível a recepção simultânea de feixes de múltiplos sinais oriundos de diferentes direções, aumentando a flexibilidade.

Embora essa arquitetura favoreça a multiplexação espacial, ela envolve altos custos, maior complexidade e consumo de energia (BRILHANTE *et al.*, 2023).




Figura 2.3: Arquitetura de *beamforming* digital. Múltiplos feixes são obtidos por meio de formadores de feixes digitais, mas ao custo de múltiplas cadeias de .

• Formação de feixe Híbrido

A arquitetura híbrida combina a formação de feixe digital e analógica, aprimorando o desempenho do *beamforming* analógico ao permitir maior quantidade de fluxos. Além disso, reduz a complexidade da arquitetura digital, pois exige menos cadeias de RF em comparação ao número de antenas. Como resultado, há uma diminuição na carga computacional, no consumo de energia e na complexidade da arquitetura (BRILHANTE *et al.*, 2023).

2.1.2 Comunicações MIMO

Em sistemas de comunicação sem fio, *Multiple Input Multiple Output* (MIMO) refere-se ao uso de múltiplas antenas no transmissor, receptor ou ambos. A técnica visa combater ou explorar a dispersão de múltiplos caminhos no canal de comunicação (ZAIDI *et al.*, 2018).




Figura 2.4: Arquitetura de *beamforming* híbrido. Gera múltiplos feixes com menos cadeias de RF por meio de configurações como: submatriz conectada, totalmente conectada, antena seletiva esparsa e arquiteturas de banda larga

Num sistema MIMO com N_t antenas transmissoras e N_r antenas receptoras, é denominado sistema MIMO $N_t \times N_r$. Por exemplo, um sistema 4X8 MIMO tem 4 antenas no transmissor e 8 no receptor.

Para mitigar o desvanecimento, utiliza-se o conceito de diversidade, no qual réplicas do mesmo sinal são transmitidas de forma independente. Isso reduz o impacto do desvanecimento, pois as réplicas possuem diferentes características, como amplitude, fase, atraso, ângulos de partida (AoD) e chegada (AoA). As formas de gerar diversidade incluem frequência, tempo, polarização e espacial. No receptor, as réplicas podem ser combinadas de diversas maneiras, como: combinação seletiva, combinação de ganho igual e *maximal ratio combining* (MRC) (DAHLMAN *et al.*, 2020; HAMPTON, 2013).

Além disso, a dispersão temporal do sinal, causada por reflexões, refrações, atenuações e difrações, resulta na chegada de múltiplas réplicas do sinal no receptor, em diferentes momentos, melhorando a confiabilidade e a capacidade do sistema.

Assim, matematicamente, um sinal s transmitido é multiplicado por um valor complexo, chamado resposta do canal, e denotado por $h_i, i = 1, \dots, N_r$, onde N_r representa o número de antenas de recepção.

Matriz de canal MIMO A matriz de canal $\mathbf{H}$ em sistemas MIMO, caracteriza como os sinais transmitidos por um conjunto de N_T antenas são recebidos em um *array* de N_R antenas, capturando os efeitos de propagação e interação do sinal com o meio.

$$\mathbf{H} = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1N_T} \\ h_{21} & h_{22} & \cdots & h_{2N_T} \\ \vdots & \vdots & \ddots & \vdots \\ h_{N_R1} & h_{N_R2} & \cdots & h_{N_RN_T} \end{bmatrix} \quad (2.1)$$

Com o intuito de maximizar o desempenho da rede, o sinal enviado também é



Figura 2.5: Propagação multi-caminho num sistema MIMO; a linha azul representa sinais recebidas por caminhos diretos e a linha vermelha representa sinais por caminhos refletidos

afetado por ajustes tanto na transmissão quanto na recepção. Portanto, são aplicados processamentos no sinal de pre-codificação ou *precoder* (W_T)¹ no transmissor e combinação ou *combiner* (W_R)² no receptor. Assim, uma completa representação do sinal recebido num *array* com N_R elementos pode ser modelado por:

$$\mathbf{y} = \mathbf{W}_R \mathbf{H} \mathbf{W}_T \mathbf{s} + \mathbf{W}_R \mathbf{n} \quad (2.2)$$

onde:

$\mathbf{y}$ contém os sinais das antenas receptoras,

$\mathbf{W}_R$ é a matriz de combinação que processa o sinal no receptor,

$\mathbf{H}$ representa a matriz de canal complexa ($N_R \times N_T$)

$\mathbf{W}_T$ é a matriz que ajusta os sinais antes da transmissão,

$\mathbf{n}$: o ruído aditivo

$\mathbf{s}$: o vetor de sinais transmitidos

Este canal de comunicação causa uma atenuação no sinal transmitido, e introduz dois tipos de desfasamento; um devido à distância entre o Tx-Rx e outro devido ao ângulo de chegada dos sinais no *array* de antenas receptoras, como representado na figura 2.6.

¹*precoder*. Define como o sinal $\mathbf{s}$ é distribuído entre as antenas transmissoras para maximizar a eficiência espectral e minimizar interferências

²*combiner* Processa os sinais recebidos no receptor para combinar os sinais úteis e rejeitar interferências ou ruído.




Figura 2.6: Representação do sinal transmitido num enlace LoS

Por tanto, cada elemento h_{ij} da matriz de canal $\mathbf{H}$ representa a resposta do canal entre a j -ésima antena transmissora e a i -ésima antena receptora, calculada como:

$$h_{ij} = \alpha e^{j\phi_{ij}}, \quad (2.3)$$

onde:

α é a atenuação do sinal, incluindo a perda de espaço livre dado por:

$$\alpha = \left(\frac{4\pi f D}{c} \right)^2 \quad (2.4)$$

com f sendo a frequência da portadora, D a distância entre transmissor e receptor, e c a velocidade da luz.

ϕ_{ij} que representa o deslocamento de fase. Composto pelo deslocamento devido a propagação do sinal ($2\pi D/\lambda$) e pelo deslocamento devido a fase relativa entre antenas ($-2\pi(N_R - 1)\sin(\theta_k)d_r/\lambda$)

Com o intuito de evidenciar a influência dos vetores de direção previamente ajustados pelo *precoder* e *combiner*, na equação 2.5 é apresentado um modelo geral do canal.

$$\mathbf{H} = \alpha \mathbf{a}_R(\theta_k) \mathbf{a}_T^H(\theta_k) \quad (2.5)$$

Como a matriz de canal $\mathbf{H}$ é determinada pela geometria do canal (posição das antenas e ângulos de chegada). É importante mencionar que nesta geometria podem ser usadas os *arrays* de antenas uniformes lineares (ULA), planares (UPA), ou circulares (UCA). Os anexos A e B apresentam como as geometrias e UCA afetam na modelagem da matriz do canal $\mathbf{H}$. Assumindo o uso de uma geometria de *arrays* linear (ULA), e assumindo que a distância D entre os *arrays* Tx e Rx é muito

maior que o tamanho de qualquer um dos *arrays* d_T e d_R , os vetores de direção são modelados como:

$\mathbf{a}_T(\theta_k)$ é o vetor de direção associado ao *array* de transmissão. com N_T antenas transmissoras, um espaçamento d_T entre os elementos das antenas no *array* do Tx, comprimento de onda λ e angulo de partida do sinal (AoD) θ .

$$\mathbf{a}_T(\theta_k) = \frac{1}{\sqrt{N_T}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi d}{\lambda} d_T \sin(\theta)} \\ \vdots \\ e^{j\frac{2\pi d}{\lambda} (N_T-1) d_T \sin(\theta)} \end{bmatrix} \quad (2.6)$$

$\mathbf{a}_R(\theta_k)$ é o vetor de direção associado ao *array* de recepção. Com N_R antenas receptoras, um espaçamento d_R entre os elementos das antenas no Rx, comprimento de onda λ e angulo de chegada do sinal (AoA) θ .

$$\mathbf{a}_R(\theta_k) = \frac{1}{\sqrt{N_R}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi d}{\lambda} d_R \sin(\theta)} \\ \vdots \\ e^{j\frac{2\pi d}{\lambda} (N_R-1) d_R \sin(\theta)} \end{bmatrix} \quad (2.7)$$

Por outro lado, os enlaces de comunicações podem se dar diretamente através de conexões com linha de visada direta (LoS) ou sem linha de visada (NLoS) .

No cenário em que o sistema possui canais com linha de visado direta (LoS), o caminho direto entre transmissor e receptor é predominantemente desobstruído, resultando em menor atenuação do sinal. Isso permite uma propagação mais eficiente da energia transmitida, reduzindo a perda de potência ao longo do percurso. Além disso, os canais LOS possuem menor dispersão temporal e espectral, o que contribui para uma maior coerência do canal. Essa característica favorece um aumento na relação sinal-ruído (SNR), facilitando a decodificação precisa da informação. Em sistemas MIMO, a presença de um componente dominante (direto) também melhora a condição da matriz de canal, tornando o sistema mais eficiente para técnicas como *beamforming* e seleção de feixes. Na Figura 2.6, é assumido que o sinal chega como uma onda plana com um ângulo de incidência θ_k . Neste caso, o *precoder* W_T é projetado para concentrar a energia do feixe no ângulo de chegada desejado AoD θ_k e o *combiner* W_R é configurado para maximizar o ganho de recepção no ângulo correspondente AoA.

Por tanto, a matriz de canal H para cenários com linha de visada direta, onde o transmissor possui N_T antenas transmissoras e um único caminho do Tx até Rx é

dada por:

$$\mathbf{H} = \sum_{K=1}^{N_T} \alpha \mathbf{a}_R(\theta_R) \mathbf{a}_T^H(\theta_T), \quad (2.8)$$

Para cenários sem linha de visada (NLoS), considera-se a contribuição de múltiplos trajetos devido a reflexões, difrações e espalhamento. A matriz $\mathbf{H}$ é expressa como uma soma de componentes de múltiplos caminhos:

$$\mathbf{H} = \sum_{l=1}^L \alpha_l \mathbf{a}_R(\theta_{R,l}) \mathbf{a}_T^H(\theta_{T,l}), \quad (2.9)$$

onde:

L : número de trajetos multipercursos;

α_l : ganho complexo associado ao l -ésimo trajeto;

$\mathbf{a}_R(\theta_{R,l})$: vetor de direção no receptor para o ângulo $\theta_{R,l}$

$\mathbf{a}_T(\theta_{T,l})$: vetor de direção no transmissor para o ângulo $\theta_{T,l}$

$(\cdot)^H$: transposta conjugada

Descrição do problema

Como foi previamente descrito, o sinal recebido y é afetado por um vetor *precoder* W_T no transmissor, um vetor *combiner* W_R no receptor, uma matriz do canal $\mathbf{H}$, e ruído n .

$$y_{(t,r)} = \mathbf{w}_t \mathbf{H} s \mathbf{w}_r^* + \mathbf{w}_r n, \quad (2.10)$$

Com o intuito de criar feixes altamente direcionados, o objetivo do *beamforming* é otimizar o *precoder* no transmissor e o *combiner* no receptor. A seleção do feixe, realiza a escolha de um subconjunto de vetores escolhidos de um *codebook* $C_T = \{W_{T_1}, \dots, W_{T_{|C_T|}}\}$ e $C_R = \{W_{R_1}, \dots, W_{R_{|C_R|}}\}$ onde $|C_T|$ e $|C_R|$ podem ser calculados a partir de técnicas baseadas em transformações matemáticas como a Transformada discreta de Fourier (DFT) (HE *et al.* (2017)), Grassmannian ou Gram-Schmidt. Assim como também, os *codebook* podem ser projetados a partir de modelos estatísticos, como os *codebook* baseados em canal ou por aprendizado de máquina.

Considerando o conjunto de todos os pares de feixes possíveis (t,r) num único índice $i \in \{1, 2, 3, \dots, m\}$, onde $m \leq |C_T||C_R|$. O objetivo do problema é selecionar o par de feixes ótimos i que maximize o sinal recebido:

$$i = \underset{i \in \{1, 2, 3, \dots, m\}}{\operatorname{argmax}} (y_i) \quad (2.11)$$

A seleção de feixe enfrenta desafios técnicos, como alta complexidade computacional, dinâmica do ambiente entre outros. Algumas técnicas propostas para resolver o problema de seleção de feixe, são: a busca exaustiva, métodos baseados em heurísticas e técnicas baseadas em aprendizado de máquina (ML) .

Portanto, este trabalho propõe o uso de técnicas baseadas em aprendizado de máquina para prever o melhor feixe com base em informações de contexto.

2.2 Redes Neurais sem Peso

As redes Neurais Sem Peso (RNSPs) são um tipo de rede neural diferente das redes neurais tradicionais, já que são compostas comumente de neurônios artificiais com entradas e saídas binárias sem pesos entre seus nós. Inicialmente, sua pesquisa ocorreu da década de 1950 até a década de 1970.

As RNSP são baseadas em redes de memórias RAM, as quais são uma representação dos neurônios. O aprendizado das RNSPs dependem das mudanças nos conteúdos das memórias, sendo esta a principal diferença com as redes neurais tradicionais que localizam seu aprendizado nos pesos das conexões, proporcionando uma alta velocidade de aprendizado. Dentre as RSNPs reportadas na literatura se encontram a rede WiSARD (Wilkes, Stonham and Aleksander Recognition Device), a rede GSN (Goal Seeking Neuron) , a GRAM (Generalization RAM) e VG-RAM (Virtual Generalization RAM) , DRASiW (FRANÇA *et al.*, 2014; LUDERMIR *et al.*, 1999; NAPOLI *et al.*, 2024; BROYLES *et al.*, 2022).

Neste trabalho, foi usada a rede WiSARD. Este modelo foi introduzido em 1981 por ALEKSANDER *et al.* (1984) na Brunel University, e foi a primeira máquina de rede neural artificial a ser patenteada e produzida comercialmente em 1984 (ALEKSANDER *et al.*, 2009). Trata-se de um modelo de aprendizado de máquina inspirado em sistemas neuromórficos e baseado na lógica distribuída. A WiSARD é uma implementação prática de um classificador que utiliza memórias associativas distribuídas para realizar tarefas de classificação, dispensando o uso de pesos contínuos, como nas redes neurais tradicionais.

2.2.1 Treinamento da rede WiSARD

A fase de treinamento, consiste em associar padrões binários a endereços de memória. Por tanto, os dados de entrada devem ser convertidos em uma representação binária por meio de técnicas como *thresholding* ou quantização. Isso permite que a rede processe os dados de forma discreta, o que simplifica as operações computacionais.

Considere um vetor de entrada $x = [x_1, x_2, \dots, x_n]$ onde $x \in \mathfrak{R}$. Durante o pre processamento x é transformado numa sequência binária $b = [b_1, b_2, \dots, b_j]$ onde

$b_j \in [0, 1]$ por meio de uma função de codificação f

$$b = f(x), \quad (2.12)$$

onde f pode ser uma quantização, *thresholding* (KIM *et al.*, 2017; HE *et al.*, 2005), rank (SAHA, 2009; ARRUDA, 2014), termômetro (LELLO *et al.*, 2020; BACELLAR *et al.*, 2024), Minchinton Cell (GRIECO *et al.*, 2010) (BHARGAVI e JYOTHI, 2014), Marr-Hildreth filter (KAPPAUN *et al.*, 2016) ou outro método adequado.

A arquitetura desta rede baseia-se em discriminadores, sendo eles responsáveis por uma categoria em problemas de classificação. A entrada binária b é particionada em k subconjuntos de bits $b^1, b^2, \dots, b^k$ pseudo-aleatoriamente mapeados, introduzindo variabilidade nos padrões. Cada tupla contém d bits, e serve como endereço para acessar as 2^d posições em uma tabela de memória associativa, chamada de RAM virtual.

$$\text{Endereço RAM}_i = \sum_{j=1}^d b_j^{(i)} \cdot 2^{d-j}, \quad (2.13)$$

No entanto, depois das tuplas serem formadas, elas serão fixadas para todo o ciclo de vida da rede neural.

Para cada classe C , a rede possui um discriminador D_r , composto por k RAMs, as quais armazenam a frequência de ocorrência de padrões binários. Assim, considerando uma entrada b pertencente à classe C , cada RAM do discriminador D_r armazena o endereço associado:

$$\text{RAM}_i^{(C)}[\text{Endereço RAM}_i] \leftarrow 1 \quad (2.14)$$

O valor armazenado na RAM é binário, indicando se o padrão correspondente já foi visto durante o treinamento. Na figura 2.7, pode ser observada uma representação gráfica deste processo .

2.2.2 Classificação da rede WiSARD

No processo de classificação, um novo padrão de entrada é endereçado às RAMs associadas de cada discriminador, e a inferência é realizada com base nas ativações dessas memórias. Os novos dados a serem avaliados usam o mesmo mapeamento de entrada que na fase de treinamento.

Considerando que uma nova entrada b é processada pelos k RAMs de cada discriminador D_r , para cada classe C , calcula-se um score de ativação S_c com base no número de RAMs que reconheceram a entrada:




Figura 2.7: Exemplo de um discriminador da letra E na fase de treinamento

$$S_c = \sum_{i=1}^k \text{RAM}_i^{(c)}[\text{Endereço RAM}_i(b)] \quad (2.15)$$

A classe atribuída à entrada será aquela com o maior *score*:

$$\hat{c} = \arg \max_c s_c \quad (2.16)$$

Na Figura 2.8, pode ser observado um exemplo de reconhecimento de caractere alfanumérico na etapa de classificação.




Figura 2.8: Exemplo de classificação de um número usando a rede WiSARD

2.2.3 Mecanismo de Bleaching na Rede WiSARD

Na rede Wisard, o mecanismo de *bleaching*, é uma técnica projetada para lidar com incertezas e ajudar a generalizar o reconhecimento de padrões. Ele desempenha um

papel crucial na inferência, ajudando a rede a classificar entradas mesmo quando parte das informações podem estar ausente ou ser ruidosa.

Nas tarefas de classificação, é possível que a WiSARD enfrente situações em que nenhum discriminador reconheça completamente uma entrada, ou duas classes tiveram a mesma resposta de saída (GRIECO *et al.*, 2010). Diante estas situações, o mecanismo *bleaching*, resolve esse problema ao introduzir um limiar progressivo de tolerância, permitindo que o modelo aceite padrões parcialmente correspondentes. Esse processo é essencial para promover a robustez e generalização da rede.

O *bleaching* funciona como um processo iterativo no qual um limiar τ é aplicado para verificar a confiança na ativação de cada classe. Inicialmente, considera-se o maior valor de ativação S_c , e as classes que não atingirem esse valor são eliminadas. Se nenhuma classe atingir o limiar inicial, o valor de τ é reduzido gradualmente até que pelo menos uma classe seja selecionada.

Este processo irá continuar até que exista uma ou mais classes com ativação suficiente para passar o limiar ou todos os valores de τ tenham sido testados.

No cenário, em que mais de uma classe atender ao critério de ativação, pode-se empregar uma estratégia de desempate, como selecionar a classe com maior ativação S_c ou resolver com base em critérios adicionais.

Pode-se destacar que o uso desta técnica tem com vantagem, uma robustez a ruído, ao permitir que a rede lide com padrões incompletos ou ruidosos, ignorando a necessidade de uma correspondência exata em todas as RAMs. Outra vantagem, é a alta capacidade de generalização, ao aceitar correspondências parciais, é capaz de aprender e reconhecer variações nos dados de entrada. E finalmente a flexibilidade, ao permitir ajustar o limiar para controlar o grau de generalização, equilibrando precisão e sensibilidade.

Porem, não deve ser desconsiderado que o processo iterativo pode aumentar o tempo de inferência em cenários com muitas classes. Assim como, o risco de over-generalização.

Se trata de adicionar um contador de frequência nas memórias RAM, quando as memórias forem lidas, um contador será incrementado se o valor acessado na memória for '1', e a resposta será retornada se valor no contador for maior ou igual ao valor de *bleaching* designado. No caso em que o empate persista, o valor *bleaching* irá aumentando geralmente em 1 até não houver mais empates.

Assim, o discriminador selecionado será aquele que tiver o maior valor na saída FRANÇA *et al.* (2014), na figura 2.9 pode ser observado um exemplo de uso do *bleaching*.

Em resumo, a rede WiSARD é configurada por dois parâmetros: 1) resolução de endereçamento de bits das memórias RAM e 2) fator de escala de dados (n).




Figura 2.9: Exemplo do uso do mecanismo *bleaching*

2.2.4 Características e Benefícios da WiSARD

A WiSARD se destaca por sua eficiência e simplicidade em relação a outras redes neurais. Alguns de seus principais benefícios incluem:

- Baixo custo computacional: A ausência de pesos contínuos elimina a necessidade de cálculos intensivos, como multiplicações de matrizes. Pois, o treinamento consiste apenas em atualizar as RAMs com base nos endereços observados, o que é altamente eficiente, e a inferência é baseada em uma soma discreta, o que reduz o custo computacional.
- Treinamento rápido: O aprendizado ocorre de maneira incremental e não envolve processos iterativos de ajuste de pesos, como o *backpropagation*.
- Robustez a ruídos: A estrutura distribuída permite lidar bem com ruídos nos dados de entrada e permite a generalização.
- Interpretação direta: A rede permite inspecionar diretamente os padrões armazenados na memória, facilitando a interpretabilidade, principalmente se a técnica DRASiW for usada (CODA *et al.*, 2023), dado que esta extensão do modelo WiSARD tem a capacidade de armazenar as frequências de padrões vistos durante a fase de treinamento em uma estrutura de dados interna, chamada “imagem mental” (MI).

Limitações

Apesar de suas vantagens, a WiSARD apresenta limitações como a escalabilidade, pois o uso de RAMs virtuais pode demandar um alto consumo de memória para conjuntos de dados muito grandes. A dependência de uma codificação binária pode limitar a precisão em tarefas que exigem maior sensibilidade a detalhes contínuos.

Aplicações

As redes neurais sem peso já possuem atuação em diversas áreas como:

- Rastreamento e modelagem de objetos em tempo real - ClusWiSARD

O principal objetivo deste trabalho é rastrear um objeto por meio de informações visuais através de uma câmera de vídeo e simultaneamente criar modelos para representar os objetos visualizados. As imagens dos objetos rastreados são utilizadas como entradas para o algoritmo que realiza a construção dos modelos, sem utilizar nenhum outro tipo de conhecimento prévio. Assim, o sistema recebe imagens em tempo real para rastrear um objeto selecionado não visto e, enquanto o rastreador está em execução, a criação do modelo de objeto é realizada para obter representações de aspectos do objeto e relacionamentos entre eles (DO NASCIMENTO e FRANÇA, 2024).

- Rede neural sem peso colaborativa - WiSARD

Neste trabalho, os autores (DA SILVA *et al.*, 2021) propõem o uso de sistemas de nuvem baseados em contêineres, como Kubernetes e Docker Swarm para realizar o treinamento/inferência através de uma arquitetura colaborativa de redes neurais sem peso. Os resultados de desempenho mostram uma eficiência na classificação de conjuntos de dados bem conhecidos em cerca de 2 vezes mais rápido do que as arquiteturas tradicionais.

- Diagnóstico de falhas na suspensão de um veículo - classificador WiSARD

Este artigo propõe classificar falhas no sistema de suspensão de um veículo usando dados de um acelerômetro e um sensor de vibração fixados no braço de controle do sistema de suspensão. O estudo avalia a rede WiSARD sob várias condições de falha, incluindo danos no suporte, falha de montagem, componentes desgastados e baixa pressão roda. Os autores SHAH *et al.* (2024) realizam uma comparação com outras técnicas de classificação e reportam uma acurácia de 95,63% com baixo tempo de teste, demonstrando potencial como candidato para sistemas de diagnóstico de falhas de veículos em tempo real.

- Agrupamento de dados de fluxo contínuo - StreamWiSARD

Neste trabalho os autores fazem uma análise de um novo sistema de agrupamento de dados de fluxo de janela deslizante, onde os discriminadores WiSARD foram usados como unidades primárias de síntese de dados (CARDOSO *et al.*, 2012).

- Sistema de classificação de *malwares* - WiSARD

Neste trabalho, os autores alcançaram 98% de acurácia na classificando entre 26 classes de software, incluindo 25 *malwares*, com menor tempo de treina-

mento. Isto pode levar a tempos de resposta rápidos em sistemas de tempo real e também proteger grandes sistemas de computador (RAMOS, 2021)

- Transferência de conhecimento - DRASiW

Os autores propõem uma metodologia para transferir memória entre sistemas DRASiW, assim como geração de clones de sistemas DRASiW com boas capacidades de classificação (DE GREGORIO e GIORDANO, 2016)

- Extração de regras - DRASiW

Neste trabalho os autores apresentam uma nova proposta de extração de regras aplicando a partir de “imagens mentais” produzidas por um multi-discriminador WiSARD/DRASiW (CARDOSO *et al.*, 2011)

- Extração de regras fuzzy a partir de imagens mentais - DRASiW

Este trabalho propõe extrair informações da frequência dos acessos de cada RAM durante a fase do treinamento, em forma de regras fuzzy (GRIECO *et al.*, 2008)

- Detecção de falhas de bombas centrífugas - classificador WiSARD

Neste trabalho, os autores categorizam as condições de falha dentro da bomba centrífuga, com o intuito de melhorar a compreensão de possíveis armadilhas operacionais, e facilitar a manutenção proativa, evitando falhas catastróficas (SHAH *et al.*, 2025),

- Jogo: pedra-papel-tesoura - WiSARD

Neste trabalho, são criados agentes adaptativos que podem jogar pedra-papel-tesoura, prevendo a estratégia do seu oponente e derrotando-o (DE SOUZA *et al.*, 2013)

- Classificação de marcadores pré-clínicos em pacientes do continuum da doença de Alzheimer - WiSARD

Neste artigo, foram investigados o diferentes níveis da doença (CN-SMD-MCI-AD) visando descobrir biomarcadores moleculares úteis para caracterizar os estágios intermediários para favorecer o tratamento específico no início da patologia. Além disso, os dados foram derivados do perfil de RMN de soros, para uma abordagem diagnóstica minimamente invasiva. (DE GREGORIO *et al.*, 2022)

- Proposta de uma nova implementação da WiSARD. Eliminação de memórias e circuitos aritméticos por a utilização de apenas funções lógicas - LogicWiSARD

Este trabalho apresenta uma nova abordagem para implementar a WiSARD de forma compacta, convertendo os nós WNN treinados de tabelas de consulta para funções lógicas. Os autores implementam esta proposta em FPGA e ASIC para ilustrar sua adequação para inferência de borda e uma redução no consumo de energia. (MIRANDA *et al.*, 2022)

- Preditor de ramificação condicional baseado em WiSARD

Este trabalho visa explorar o ganho potencial em precisão e os custos estimados de hardware do uso de um preditor de ramificação baseado em WiSARD. Os autores tratam este problema como um problema de classificação binária e exploram como ele executa uma metodologia de treinamento *on-line one-shot* (VILLON *et al.*, 2023)

- Implementação de RNS em hardware - DWN

Em (BACELLAR *et al.*, 2024), os autores propõem uma nova técnica - DWN (redes neurais sem peso diferenciáveis). Esta técnica permite a diferenciação aproximada de valores binários, o que possibilita o desenvolvimento de arquiteturas de redes neurais sem peso de multicamadas com grandes tabelas de pesquisa. Durante a fase de treinamento, é possível que o modelo aprenda as conexões de diferentes tabelas de pesquisa. Esta técnica também propõe uma estratégia de normalização específica para tabelas de pesquisa em redes neurais sem peso, com o intuito de melhorar a estabilidade do modelo e evitar *overfitting*. Este trabalho apresenta uma implantação da proposta numa FPGA, assim como também uma comparação de desempenho com outras técnicas. Como resultado, os autores reportam que a DWN superou as técnicas de *baseline* em termos de redução de consumo de energia. Por outro lado, a técnica proposta também foi implementada num microcontrolador de baixo custo, e como resultado a DWN alcançou em média, maior precisão e velocidade de execução. E finalmente uma implementação em chips de custo ultra-baixo, onde se mostrou com uma notável redução na área do circuito. Este trabalho é muito promissório em aplicações onde o alto rendimento ou baixa latência são críticos, assim como também em cenários onde seja necessário o uso de dispositivos com restrições ou de baixo custo.

Outras aplicações das redes neurais sem peso são: reconhecimento de sinais de trânsito (FORECHI *et al.*, 2016), interpretação de linguagem natural (LYRIO *et al.*, 2015), detecção de *fake news* (SPALENZA *et al.*, 2020), análise de crédito (CARDOSO *et al.*, 2016), dados criptografados (NEUMANN *et al.*, 2024), reconhecimento de padrões de sinal WiFi (CARDOSO *et al.*, 2013), classificação dos

subtipos do HIV-1 (SOUZA *et al.*, 2012), classificação da trajetória do GPS (BARBOSA *et al.*, 2018), mineração de texto (RANGEL *et al.*, 2021), rastreamento de alvos (DA SILVA MOREIRA e EBECKEN, 2013), categorização de texto (BADUE *et al.*, 2008), reconhecimento de imagens (YORK e DUGGAN, 1997), sistemas de recomendação (COTTA, 2018), detecção e diagnósticos de falhas em módulos fotovoltaicos (SRIDHARAN *et al.*, 2023).

Contudo, no contexto de seleção de feixe para redes celulares, até o momento não foi achada nenhuma referência na literatura.

2.3 Estratégias para seleção de dados em aprendizado *on-line*

Historicamente, os seres humanos desenvolveram diversas ferramentas para simplificar tarefas e atender às necessidades do dia a dia. Na era da digitalização, com a abundância de informações disponíveis, a demanda por aprendizado de máquina tem crescido significativamente. Para interpretar esses dados e torná-los úteis na resolução de problemas, surgiram técnicas que permitem explorar a informação de forma mais eficiente.

Segundo Arthur Lee Samuel, o aprendizado de máquina é o campo de estudo que confere aos computadores a capacidade de aprender sem serem explicitamente programados. Essa abordagem permite que as máquinas processem dados de forma eficiente por meio de diferentes algoritmos e modelos. No entanto, não há um único modelo ideal para todos os problemas; a escolha da técnica mais adequada depende de diversos fatores, como a natureza do problema, o número de variáveis envolvidas e as características do modelo mais apropriado para a tarefa (MAHESH, 2020).

O aprendizado *on-line* é um tipo de aprendizado de máquina em que um modelo executa uma tarefa preditiva aprendendo continuamente a partir de dados recebidos de forma sequencial, ajustando seus parâmetros a cada nova entrada. Em contraste, no aprendizado *offline* (ou *batch*), o modelo é treinado com um conjunto de dados fixo antes de ser implantado para inferência, sem atualizações posteriores. Esse paradigma exige que todos os dados de treinamento estejam disponíveis previamente, e o treinamento geralmente ocorre em um ambiente *offline* devido ao alto custo computacional envolvido.

Nesse contexto, um algoritmo de aprendizado *on-line* tem como objetivo maximizar a precisão de uma sequência de previsões. De maneira geral, o algoritmo recebe um exemplo, faz uma previsão, compara o resultado com a resposta correta e ajusta seu modelo antes de processar o próximo dado. Esse processo de aprendizado é incremental, com a descoberta dos rótulos das previsões ocorrendo um a um.

Essa abordagem permite que o sistema se adapte a mudanças no ambiente, tornando-o ideal para cenários em que os dados são recebidos de forma dinâmica e contínua. Com o intuito de resumir algumas das principais técnicas utilizadas no aprendizado *on-line*, de acordo com seus princípios específicos (HOI *et al.*, 2021), a Figura 2.10 apresenta uma classificação dessas abordagens.

Um dos principais desafios deste paradigma é a descoberta dos “rótulos” das previsões, pois nem sempre esses rótulos estão disponíveis, o que exige a tomada de




Figura 2.10: Classificação de técnicas usadas no aprendizado *on-line*

decisões sobre quais exemplos devem ser rotulados e quando. A obtenção de rótulos para novas instâncias impacta diretamente a eficiência do aprendizado *on-line*. Técnicas como o aprendizado ativo tentam minimizar a necessidade de rotulagem, solicitando *feedback* apenas para instâncias que geram maior incerteza no modelo. De acordo com CACCIARELLI e KULAHCI (2024), o aprendizado *on-line* ativo pode ser dividido em três categorias principais, dependendo de como as instâncias não rotuladas são apresentadas ao modelo e selecionadas para rotulagem:

1. Síntese de Consulta: O modelo pode solicitar rótulos de qualquer amostra na entrada, permitindo flexibilidade total. Exemplos de aplicações incluem classificação de imagens, processamento de linguagem natural (NLP) e reconhecimento de fala.
2. Aprendizado Baseado em Pool: Nesse cenário, um conjunto predefinido de dados não rotulados é disponibilizado, e o modelo escolhe os exemplos mais informativos para anotação. Esses exemplos são rotulados, e o modelo é re-treinado iterativamente. As principais estratégias nesse contexto incluem:
 - Amostragem por Incerteza: Seleção de pontos com maior incerteza;
 - Consulta por Comitê: Uso de múltiplos modelos para identificar exemplos que geram maior desacordo entre eles;
 - Amostragem Ponderada por Densidade: Priorização de pontos representativos na distribuição dos dados.
3. Aprendizado *on-line* ativo: Aqui, as instâncias são geradas em um fluxo contínuo e não podem ser armazenadas integralmente antes que uma decisão seja tomada. Este tipo de aprendizado é crucial em aplicações que exigem decisões

em tempo real, como sistemas de monitoramento de fraudes ou análise de redes sociais. Estratégias utilizadas para gerenciar o fluxo contínuo de dados no aprendizado *on-line* ativo são:

- Algoritmos de passagem única (Single-Pass): Esta técnica avalia cada ponto de dado em tempo real e toma decisões imediatamente. Ideais para cenários com restrições de tempo, como detecção de fraudes, onde decisões rápidas são essenciais.
- Métodos baseados em janela (Window-Based): Nesta técnica, são processados blocos de dados de tamanho fixo e selecionam as observações mais informativas dentro desse conjunto. A “amostragem do melhor fora da janela” é um exemplo comum, onde o modelo escolhe as k instâncias mais úteis para rotulagem. Úteis em cenários com grandes volumes de dados e menos restrições de tempo.

Ao projetar estratégias de aprendizado *on-line* ativo, é fundamental considerar a natureza do fluxo de dados, que pode ser classificado como estacionário ou flutuante.

Fluxos de dados estacionários são caracterizados por processos de geração de dados estáveis, nos quais as propriedades estatísticas permanecem constantes ao longo do tempo. Em contrapartida, fluxos de dados flutuantes apresentam variações nas propriedades estatísticas ao longo do tempo, devido a mudanças nos processos de geração dos dados. Essa distinção é crucial, pois estratégias desenvolvidas para fluxos estacionários podem não ser eficazes em fluxos flutuantes, o que pode levar a um desempenho abaixo do esperado.

Dessa forma, as estratégias de aprendizado *on-line* ativo precisam ser adaptadas conforme a natureza do fluxo de dados, para otimizar seu desempenho. A capacidade de identificar o tipo de fluxo e ajustar as técnicas de aprendizado em conformidade é essencial para garantir a eficácia em aplicações práticas.

Em síntese, o aprendizado *on-line* tem-se consolidado como uma área central da inteligência artificial, especialmente devido à crescente demanda por sistemas inteligentes em aplicações que envolvem grandes volumes de dados e ambientes dinâmicos, como é o caso da seleção de feixe em redes veiculares.

Capítulo 3

Revisão Bibliográfica

As comunicações de ondas milimétricas abrangem uma ampla faixa de frequências, de 30 GHz a 300 GHz, oferecendo novas oportunidades para o uso do espectro em aplicações de banda larga. Para o 5G, especificamente, a União Internacional de Telecomunicações (ITU) atribuiu as bandas de frequência de 28–38 GHz e 70–90 GHz durante a Conferência Mundial de Radiocomunicações de 2019 (WRC-19) (CUNERAY *et al.*, 2023).

Apesar das vantagens associadas ao uso dessas bandas, os sistemas baseados em ondas milimétricas enfrentam desafios significativos, como absorção atmosférica, alta atenuação, perda de caminho e baixa difração em torno de obstáculos. Para mitigar esses problemas, empregam-se enlaces altamente direcionais, que dividem o domínio espacial em setores, sendo cada setor associado a um feixe transmissor e a um feixe receptor. Essa estrutura conforma o *beam space*, sendo este uma representação alternativa dos sinais em sistemas de comunicação que utilizam formação de feixe (*beamforming*). Nesse contexto, os sinais são transformados do domínio espacial, associado às antenas físicas, para um domínio angular, onde a energia é concentrada em direções específicas, correspondendo aos feixes.

O desempenho do *beamforming* está diretamente relacionado ao número de antenas no sistema: quanto maior o número de elementos de antena, maior o ganho na formação do feixe. Essa técnica permite modificar o padrão de radiação de um arranjo de antenas, tornando-o mais diretivo, caso necessário, ou ajustando dinamicamente a direção do feixe principal (BRILHANTE *et al.*, 2023).

Um dos principais desafios dos sistemas baseados em ondas milimétricas é a descoberta e seleção de feixes, especialmente quando informações de contexto fora de banda não estão disponíveis. Existem duas abordagens predominantes para enfrentar esse problema: i) varredura exaustiva de feixes: nesta abordagem, o transmissor e o receptor medem exaustivamente a potência recebida de todos os pares possíveis de feixes (Tx-Rx) até identificar a combinação que maximiza a potência do sinal; ii) busca hierárquica: o receptor inicialmente analisa o canal de feixes largos e, gra-

dualmente, restringe a busca para feixes mais estreitos. Atualmente, os padrões celulares para comunicação em bandas milimétricas adotam a varredura exaustiva como procedimento padrão. No entanto, com o aumento projetado no número de antenas nos sistemas futuros, essa abordagem torna-se progressivamente inviável, devido à sobrecarga computacional e ao aumento da latência no processo de seleção de feixes.

Por outro lado, as técnicas de aprendizado de máquina têm permeado transversalmente a arquitetura das novas gerações de redes celulares, posicionando-se como tecnologias habilitadoras em diversos campos das telecomunicações. Isso se deve, principalmente, às suas capacidades de generalização e ao impacto significativo na otimização de processos complexos. No contexto da seleção de feixes, o uso de aprendizado de máquina tem se mostrado promissor para integrar métodos inteligentes que garantam o estabelecimento de enlaces confiáveis em cenários desafiadores.

Na literatura recente, diversos trabalhos exploraram o uso de aprendizado de máquina para auxiliar na tarefa de seleção de feixes. Este capítulo apresenta uma revisão abrangente, cujo objetivo é identificar e analisar os estudos que abordam o problema de seleção de feixes a partir de informações de contexto, utilizando técnicas de aprendizado de máquina.

Esse problema tem sido amplamente investigado pela comunidade científica. Para a realização deste trabalho, foram realizadas pesquisas em bibliotecas digitais renomadas, como Google Scholar, IEEE Xplore, ACM Digital Library e Sensors. As consultas foram repetidas ao longo de todo o processo de pesquisa, com o objetivo de incluir artigos publicados recentemente. As strings de busca utilizadas incluíram: *“beam-selection”*, *“beam-selection + lidar”*, *“codebook design + lidar”* e *“machine learning beam-selection”*.

O critério de seleção dos trabalhos foi baseado na relevância do título e do resumo para o desafio proposto, ou seja, a seleção de feixes utilizando alguma técnica de aprendizado de máquina. Os artigos analisados compreendem o período entre 2018 e 2024. Em um primeiro estágio, foram identificados 70 artigos relevantes. Contudo, após uma leitura detalhada, foram selecionados apenas aqueles que abordassem especificamente a seleção de feixes a partir de informações de contexto, utilizando algum tipo de aprendizado de máquina. No total, 22 artigos foram escolhidos como estado da arte para este trabalho.

Com o objetivo de organizar e classificar as contribuições dos trabalhos analisados, a Tabela 3.1 apresenta um resumo das principais contribuições da literatura recente. Os artigos foram agrupados em três categorias principais, com base no tipo de dados utilizados como informações contextuais.

O primeiro grupo de pesquisas é composto por estudos que utilizam entradas de diferentes tipos, como sinais de pilotos, imagens capturadas por câmeras, dados de

sensores (por exemplo, radar) e informações de posição do receptor (Rx) baseadas em GPS. No segundo grupo, encontram-se trabalhos que combinaram dados de sensores LiDAR com outras entradas, como informações de GPS ou imagens de câmeras, ampliando o contexto disponível para a seleção de feixes. Por fim, o terceiro grupo reúne pesquisas que empregam exclusivamente informações provenientes de sensores LiDAR para a tarefa de seleção de feixe.

Nesta tabela, também são detalhados os diferentes métodos explorados pelos autores para seleção de feixe, as configurações de antenas assumidas em cada estudo e os conjuntos de dados utilizados em cada referência. Entre as pesquisas analisadas, destaca-se o uso de Redes Neurais Profundas (DNNs), uma técnica amplamente aplicada a problemas de seleção de feixes devido à sua capacidade de processar dados de alta dimensão e identificar padrões complexos.

Alguns autores exploraram abordagens específicas, como Redes Neurais Convolucionais (CNNs), que aprendem características espaciais a partir de representações 2D/3D, e Perceptrons Multicamadas (MLPs). Além disso, outros trabalhos empregaram estratégias mais tradicionais, como Máquinas de Vetores de Suporte (SVMs) lineares ou árvores de decisão, demonstrando a diversidade de métodos aplicados à tarefa de seleção de feixe.

Em KLAUTAU *et al.* (2018), os autores investigaram o desempenho de diferentes técnicas de aprendizado de máquina para seleção de feixe utilizando um conjunto de antenas planas uniformes no transmissor (Tx) e no receptor (Rx), cada um com $N_t = N_r = 16$ elementos. Os experimentos analisaram o desempenho top-1 das conexões em cenários de linha de visada (LOS), sem linha de visada (NLOS). Os autores compararam diversas técnicas de aprendizado de máquina utilizando informações de GPS como entrada. Os resultados top-1 reportados para cada técnica foram os seguintes: SVM linear: 33,2%; AdaBoost: 55%; Árvore de decisão: 55,5%; Floresta aleatória: 63,2%; DNN: 63,8%; DQN: 67,5%. Os resultados mostram que as técnicas baseadas em aprendizado profundo, como Redes Neurais Profundas (DNNs) e Redes Neurais Profundas com Reforço (DQN), alcançaram os melhores desempenhos, destacando sua capacidade de generalização em cenários complexos de seleção de feixe.

Em DIAS *et al.* (2019), os autores avaliaram o desempenho da detecção de linha de visada (LOS), a precisão da seleção de feixe top-k para cenários LOS e NLOS, além do throughput (RT) ao utilizar dados LiDAR como entrada.

O estudo explorou diferentes arquiteturas para a utilização do LiDAR, incluindo: LiDAR distribuído, LiDAR centralizado, LiDAR@BS (LiDAR na estação base) e Posição. Para essas tarefas, foi empregada uma Rede Neural Profunda (DNN) composta por 13 camadas, das quais 7 eram camadas convolucionais 2D com tamanhos de kernel decrescentes. A técnica utilizou o otimizador Adadelta para o treinamento.

Referencia	Tipo de entrada	Técnica de aprendizado	Tipo de antena	Dataset
KLAUTAU <i>et al.</i> (2018)	GPS	DNN, Depp RL, AdaBoost, Linear SVM, Decision tree, Random Forest	UPA 4X4	Raymobtime
LI e ALKHATEEB (2019)	pilots	DNN	ULA 64X64	Deep MIMO
XU <i>et al.</i> (2020)	images	DNN	-	Generate
GUI <i>et al.</i> (2021)	pilots	IFML	-	-
NGUYEN e NGUYEN (2022)	pilots	LSTM	-	Deep MIMO
COUSIK <i>et al.</i> (2022)	pilots	DNN	UPA	Generate
GONZÁLEZ-PRELCIC <i>et al.</i> (2016)	Radar	-	UPA	Generate
CHATZOGLOU e GOUDOS (2023)	GPS	MLP CNN	UPA 4X4	Raymobtime
REUS-MUNS <i>et al.</i> (2021)	images GPS	DNN	ULA 32X8	Raymobtime
GUPTA <i>et al.</i> (2023)	GPS LiDAR	ViT model	-	Raymobtime
CHEN <i>et al.</i> (2023)	GPS LiDAR	CNN	UPA 16X4	Raymobtime
RUSECKAS <i>et al.</i> (2021)	GPS LiDAR	MLP CNN	ULA 32X8	Raymobtime
KLAUTAU <i>et al.</i> (2019)	LIDAR, GPS	DNN	UPA 16X4	Raymobtime
SALEHI <i>et al.</i> (2022)	LiDAR, images, GPS.	DNN	ULA 32X8	Raymobtime NEU
MASHHADI <i>et al.</i> (2021)	LiDAR GPS	Federated NN	-	Raymobtime
KLAUTAU <i>et al.</i> (2021)	LiDAR GPS images	DNN	ULA 64X8	Raymobtime
MANJARRES <i>et al.</i> (2024)	LiDAR, GPS	SVC, KNN, WiSARD, Decision Tree, Random Forest	ULA 32X8	Raymobtime
ZHENG <i>et al.</i> (2021)	LiDAR	3D CNN	-	Raymobtime
DIAS <i>et al.</i> (2019)	LiDAR	DNN	UPA	Raymobtime
ZECCHIN <i>et al.</i> (2022)	LiDAR	CNN	-	Raymobtime
XU <i>et al.</i> (2020)	LiDAR	DNN	UPA	Generate

Tabela 3.1: Comparação de trabalhos relacionados

Os resultados indicaram que a arquitetura LiDAR centralizado obteve um desempenho top-1 relativamente modesto. Para conexões LOS, a precisão foi de aproximadamente 20%, enquanto para conexões NLOS, a precisão foi de cerca de 15%.

Em KLAUTAU *et al.* (2019), os autores investigaram uma arquitetura distribuída que combina dados de GPS e LiDAR. O estudo considerou apenas uma cadeia de radiofrequência (RF) e utilizou codebooks de feixe fixo. Para o transmissor (Tx) e o receptor (Rx), foi adotada uma matriz planar uniforme (UPA), com dimensões 16×16 na estação base e 4×4 no receptor.

A abordagem proposta utilizou técnicas de aprendizado de máquina (ML) para detectar o tipo de conexão (LOS ou NLOS). A partir dessa estimativa, uma rede neural profunda (DL) foi aplicada de forma condicionada ao estado estimado (LOS ou NLOS) para realizar a seleção de feixe. A DNN foi configurada com o otimizador Adadelta do Keras, composta por 13 camadas, sendo 7 delas convolucionais 2D com tamanhos de kernel decrescentes, variando de 13×13 até 1×1 . Na saída, foi utilizada a função de ativação softmax para classificação top-k. Os resultados mostraram desempenhos distintos para conexões LOS e NLOS. Para a classificação top-1, a precisão na conexão LOS foi de 45%, enquanto na conexão NLOS foi de pouco menos de 20%. Já a taxa de transferência alcançada para top-k=10 foi de 0,97 em cenários LOS e 0,69 em cenários NLOS.

Em ZHENG *et al.* (2021), os autores propuseram o uso de uma rede neural convolucional 3D (conv3D) para a tarefa de seleção de feixe utilizando dados LiDAR como entrada. O estudo considerou a formação de feixe analógica e uma única cadeia de radiofrequência (RF) entre cada transmissor (Tx) e receptor (Rx). O trabalho avaliou dois métodos distintos: redes convolucionais 2D (conv2D) e 3D (conv3D). No modelo conv3D, foram utilizadas treze camadas convolucionais, sendo as três primeiras operações convolucionais configuradas como 2D, e o restante ajustado para convoluções 3D. Além disso, a arquitetura incluiu duas camadas densas no final, e o otimizador Adam foi empregado para a otimização estocástica dos pesos. Os resultados experimentais destacaram os seguintes desempenhos para a seleção de feixe top-1: o método conv2D obteve uma precisão de 62,2%, enquanto o método conv3D apresentou um desempenho ligeiramente superior, alcançando 63,3%.

Em ZECCHIN *et al.* (2022), foi proposta uma abordagem para seleção de feixe baseada em redes convolucionais (CNN) utilizando dados de sensores LiDAR e informações de localização (GPS). O sistema considerou formação de feixe analógica com uma única cadeia de radiofrequência (RF). A arquitetura da rede neural é composta por 6 camadas convolucionais, seguidas por 5 camadas lineares. No fluxo de processamento, os dados LiDAR passam inicialmente pelas 6 camadas convolucionais, seguidas de uma camada linear. Em seguida, os recursos extraídos são concatenados com os dados de GPS, formando a entrada para as 3 camadas lineares subsequentes, cada uma composta por 64 neurônios. A última camada linear é responsável por produzir a saída final, correspondente à seleção de feixe. Para reduzir a complexidade computacional, os autores implementaram uma técnica de poda de rede

(pruning). Essa abordagem remove neurônios ou filtros com menor contribuição, baseada na menor norma L1 dos pesos, resultando em uma rede mais eficiente sem comprometer significativamente o desempenho. O desempenho foi avaliado utilizando métricas de precisão da classificação top-k e taxa de transferência top-k. Os resultados mostraram que a precisão da classificação top-1 atingiu 59,5%, enquanto a taxa de transferência top-1 alcançou 79,9%.

Em SALEHI *et al.* (2022), foi proposto um *framework* de aprendizado profundo baseado em fusão (F-DL) utilizando dados multimodais para prever o conjunto de pares de feixes top-K. Os dados de entrada considerados foram provenientes de sensores GPS, câmera e LiDAR. O sistema empregou um arranjo linear uniforme (ULA) para transmissão (Tx) e recepção (Rx), com 32 elementos no transmissor e 8 elementos no receptor. Os autores avaliaram os modelos propostos em três arquiteturas unimodais (uma para cada tipo de dado) e, posteriormente, em uma arquitetura de fusão. Para a rede unimodal baseada em GPS, foi utilizada uma camada convolucional 1D. Já para os modelos unimodais baseados em dados LiDAR e imagens, as redes foram inspiradas na arquitetura ResNet. A rede de fusão combinou as informações das arquiteturas unimodais, concatenando as saídas das últimas camadas de cada modelo. O treinamento foi realizado utilizando o otimizador Adam. Os resultados de precisão para a classificação top-1 indicaram o seguinte desempenho: Coordenadas (GPS): 12,32%; Imagens: 12,39%; LiDAR: 46,23%; Coordenadas + Imagens: 25,76%; Coordenadas + LiDAR: 55,42%; Imagens + LiDAR: 54,52%; Coordenadas + Imagens + LiDAR: 56,22%. Esses resultados demonstram que a combinação de múltiplos dados de entrada, particularmente quando incluem LiDAR, proporciona uma melhoria significativa no desempenho da seleção de feixe.

Em KLAUTAU *et al.* (2021) os autores propõem usar uma estrutura baseada em RT que suporta redes de comunicação e inteligência artificial imersas em realidade virtual ou aumentada (CAVIAR). Eles consideraram uma ULA no Tx/Rx com 64 elementos e 8 elementos respectivamente, e assumindo uma arquitetura MIMO analógica. Os dados de entrada usados são LiDAR, posição e imagens. Os autores avaliaram uma orientação correta (Co) na antena e orientação fixa (Fo) independentemente de qualquer rotação do veículo para dados LiDAR e para dados multimodais. As métricas usadas para avaliação foram uma precisão top-k e estimativa de canal. A precisão top-1 para Co LiDAR foi de 42% aproximadamente.

Em MASHHADI *et al.* (2021), foi proposto o uso de uma técnica CNN federada para seleção de feixes de dados LiDAR. Os autores consideraram um sistema OFDM mmWave, Com o objetivo de reduzir a complexidade do modelo, eles propuseram usar uma representação LiDAR em 2D, descartando os dados de altura ao longo do eixo z. Esta arquitetura é composta por 6 camadas de convoluções e 2 camadas lineares com função de ativação ReLU e softmax na saída e o otimizador Adam

foi usado. As métricas de avaliação foram a precisão da classificação top-k e a taxa de transferência top-k. Os autores comparam seus resultados usando como *baseline* o trabalho apresentado por DIAS *et al.* (2019) e KLAUTAU *et al.* (2019). Os resultados obtidos para o top-1 foram 50% aproximadamente de acurácia e 70% da taxa de transferência.

Em (CHATZOGLU e GOUDOS, 2023) foi feito um estudo comparativo de diferentes métodos de ML usados por KLAUTAU *et al.* (2018) para resolver o problema de seleção de feixes. Ambos os trabalhos usaram um conjunto de dados s000 do Raymobtime, com 64 classes para classificação. Neste trabalho, os autores propõem algumas estratégias para executar os modelos avaliados. - Remoção de 5 classes de todos os conjuntos de dados, pois foi observado que essas classes tinham apenas uma amostra. - Geração de dados sintéticos usando a Técnica de Sobreamostragem de Minoria Sintética (SMOTE), para estender o conjunto de dados fornecido. - O ajuste do modelo foi realizado usando o algoritmo GridSearch. As técnicas de aprendizado de máquina avaliadas foram: Regressão logística, Naive Bayes, AdaBoost, Linear SVC, Classificador SGD, Light GBM, KNN, Árvore de decisão, Random Forest, NN, ET. E finalmente, foram acrescentados os modelos de DNN, MLP e CNN para avaliação. No modelo MLP foram utilizadas 11 camadas e para CNN foram utilizadas 16 camadas, ambos utilizaram um otimizador SGD. Os autores relatam uma acurácia de 94% na seleção de feixe.

No trabalho apresentado por CHEN *et al.* (2023), também foi usada a estratégia de geração de dados sintéticos através da técnica AugMix. A seleção de feixe foi realizada usando um CNN com dados LiDAR. Os autores implementaram uma transformação dos dados LiDAR 3D em 2D por meio de 6 camadas convolucionais e 5 camadas densas, depois disso, os dados GPS adicionados foram mesclados com dados LiDAR por meio de camadas ReLU. E, finalmente, a última camada usada foi com uma função softmax. Para esta avaliação, foi usado o dataset Raymobtime s008 e s009, e as métricas avaliadas foram acurácia e taxa de transferência (RT). Esta proposta foi comparada com a seleção de feixe de ondas milimétricas com base em dados LIDAR com Aprendizado de Máquina (LBS-ML) de KLAUTAU *et al.* (2019), Seleção de Feixe de CNN Não Local Auxiliada por LIDAR (LNBS) de ZECCHIN *et al.* (2022) e Seleção de Feixe de Ondas Mm com Base em Aprendizado Profundo (DLBS) de ZHENG *et al.* (2021). Os autores reportam os resultados, top-10 e top-50 de 95.1% e 97.7% de acurácia, respectivamente, e no top-5 um 96.2% de RT.

No trabalho apresentado por RUSECKAS *et al.* (2021), foi proposta uma junção do modelo MLP e uma rede neural convolucional (CNN), usando como informações de contexto os dados de posição GNSS e dados LiDAR. Para avaliar o método proposto, os autores usaram os *subset* s008 e s009 do *dataset* Raymobtime. Como resultado, foi apresentada a acurácia top-1 nos dados de validação, onde foi alcançado

64% e 91% no top-5 usando dados GNSS.

MANJARRES *et al.* (2024) apresentaram uma comparação entre 5 técnicas de aprendizado de máquina para realizar a seleção de feixe. Os autores usam como dados contextuais, informações dos sensores lidar e coordenadas GPS. Para os treinamentos e teste dos modelos, os autores usaram *subset s008* do Raymobtime. Nesta comparação foi apresentada a seleção de feixe top-k e como resultado principal, os autores mostram um desempenho top-1 na acurácia de 71% da rede WiSARD, usando como dados multimodais (LiDAR + GPS).

Com o intuito de resumir os resultados dos trabalhos que usaram o *dataset* Raymobtime, na Tabela 3.2 é apresentado o desempenho alcançado pelas diferentes técnicas implementadas.

Técnica	Entrada	Acurácia[%]			Referência
		Top-1	Top-10	Top-20	
Linear SVM	GPS	33.2	-	-	KLAUTAU <i>et al.</i> (2018)
AdaBoost		55.0	-	-	
Decision Tree		55.5	-	-	
Random Forest		63.2	-	-	
DNN		63.8	-	-	
DQN		67.5	-	-	
DNN	LiDAR	20.5	33.0	49.5	DIAS <i>et al.</i> (2019)
DL	LiDAR, GPS	42.0	90.0	98.0	KLAUTAU <i>et al.</i> (2019)
Conv3D	LiDAR	63.3	92.5	-	ZHENG <i>et al.</i> (2021)
KNN	GPS	43.0	-	-	CHATZOGLOU e GOUDOS (2023)
Naive Bayes		8.70	-	-	
ANN		40.50	-	-	
Lightweight NN	LiDAR, GPS	59.5	-	87.0	ZECCHIN <i>et al.</i> (2022)
F-DL	LiDAR	46.2	89.9	96.1	SALEHI <i>et al.</i> (2022)
DNN	LiDAR	32.0	80.0	-	XU <i>et al.</i> (2020)
Dense Neural Network	LiDAR	43.0	82.0	85.0	KLAUTAU <i>et al.</i> (2021)
WiSARD	LiDAR, GPS	71.0	95.0	98.0	MANJARRES <i>et al.</i> (2024)

Tabela 3.2: Comparação dos resultados alcançados pelos trabalhos da revisão bibliográfica

Embora essas abordagens resolvam o problema de seleção de feixes com precisão aceitável, a limitação mais comum é que são técnicas computacionalmente caras e difíceis de treinar. Requerem grandes quantidades de dados para procedimentos de treinamento e a fase do modelo de treinamento pode ser lenta e instável. Outra limitação das DNN que podemos considerar é a dificuldade de adaptação a ambientes em rápida mudança. Em cenários em que sejam necessárias atualizações muito fre-

quentes (por exemplo, a cada poucos segundos ou minutos), o tempo de treinamento das DNNs pode ser um gargalo. Se os recursos computacionais forem limitados, o custo de retreinamento ou ajuste fino pode superar os benefícios.

Até a data deste trabalho, não foi encontrado na literatura uma comparação justa de desempenho entre diferentes técnicas utilizadas pelos autores, e avaliações como desempenho computacional. Este trabalho pretende comparar os métodos existentes que têm parametrização semelhante, que usam os mesmos dados para treinar e testar seus modelos e analisar o desempenho computacional.

Após análises dos trabalhos apresentados anteriormente, foi escolhida a abordagem apresentada por SALEHI *et al.* (2022) e por RUSECKAS *et al.* (2021) como modelos de *baseline* para desenvolver a comparação de desempenho proposta neste trabalho.

Capítulo 4

Análises de dados

Neste capítulo, apresentamos os principais elementos e etapas envolvidos no estudo. Inicialmente, descrevemos o *dataset* utilizado ao longo do trabalho, destacando suas características e justificando sua escolha. Em seguida, detalhamos o pré-processamento aplicado aos dados, com foco nos ajustes necessários para garantir a eficácia da rede WiSARD. Também introduzimos os modelos considerados como *baselines*, fornecendo um panorama das abordagens existentes para comparação. Por fim, discutimos a metodologia de avaliação adotada e realizamos uma análise comparativa de desempenho entre as técnicas avaliadas, utilizando métricas de acurácia para embasar os resultados obtidos.

4.1 Análise do Dataset

Para este estudo, foi usado o dataset Raymobtime¹, amplamente reconhecido na literatura por sua aplicação em diversas técnicas. Este *dataset* foi desenvolvido com o objetivo de criar simulações realistas de sistemas de comunicação em redes veiculares através da técnica traçado de raios ou *ray-tracing*. O *ray-tracing* é uma ferramenta computacional usada para modelar a propagação de ondas eletromagnéticas na faixa de ondas milimétricas. Esta técnica simula como as ondas de rádio interagem com o ambiente, considerando efeitos como reflexão, difração e espalhamento em superfícies de edifícios, veículos e outros obstáculos.

Para atingir esse propósito, os autores integraram diversos softwares, como o Cadmapper² e o OpenStreetMaps³, responsáveis por modelar cenários 3D *outdoor* realistas, o SUMO⁴, que fornece a mobilidade dos veículos, e o Wireless InSite⁵, encarregado da geração de traçados de raios para os canais de comunicação.

¹<https://www.lasse.ufpa.br/raymobtime/>

²<https://cadmapper.com>

³<https://www.openstreetmap.org/#map=4/-15.13/-53.19>

⁴<https://sumo.dlr.de/userdoc/>

⁵<https://www.remcom.com/wireless-insite-em-propagation-software/>

O resultado dessa integração é um conjunto de dados composto por informações de traçado de raios, nuvem de pontos providas pelo sensor LiDAR, imagens de câmeras e informações de posição (x,y,z) dos receptores KLAUTAU *et al.* (2018). Na Figura 4.1 é possível evidenciar um diagrama de blocos da composição do Raymobtime.




Figura 4.1: Diagrama de blocos do *dataset* Raymobtime tomado de LASSE (2020)

O *dataset* Raymobtime contém nove cenários distintos, identificados como s000 a s009. Os cenários s000 a s006 incluem apenas dados de *ray-tracing*, enquanto os cenários s007 a s009 também incorporam dados LiDAR. Cada cenário é subdividido em episódios, que por sua vez são compostos por cenas. Embora haja uma relação temporal entre as cenas, essa relação não é obrigatória entre os episódios. Na Tabela 4.1, são apresentados todos os *dataset* que compõem o Raymobtime com suas características principais.

Dataset	Quantidade de Rx	Numero de episódios	Cenas por episódios	Tempo entre episódios	Tempo entre cenas	Dados multimodais ¹
s000	10 Móvel	116	50	30 s	100 ms	✗
s001	10 Fixo	200	10	37 s	5 ms	✗
s002	10 Fixo	1800	1	3 s	1 s	✗
s003	10 Fixo	200	10	35 s	1 ms	✗
s004	10 Móvel	5000	1	30 s	1 s	✗
s005	10 Fixo	125	80	35 s	10 ms	✗
s006	10 Fixo	200	10	35 s	1 ms	✗
s007	10 Móvel	50	40	5 s	1 s	✓
s008	10 Móvel	2086	1	30 s	0.1 s	✓
s009	10 Móvel	2000	1	30 s	0.1 s	✓

Tabela 4.1: Descrição dos sub-conjuntos do *dataset* Raymobtime

¹Dados de LiDAR, imagens de câmeras e Ray-tracing

Para este trabalho, foram selecionados os subconjuntos s008 e s009, nos quais os dados foram coletados em um ambiente que simula uma rua tipo cânion, localizada em Rosslyn, Virginia. Nesse cenário, a estação base está posicionada a uma altura de 4 metros e equipada com câmera e sensor LiDAR, enquanto 10 receptores móveis estão espalhados ao longo da rua, conforme ilustrado na Figura 4.2.



Figura 4.2: Representação do cenário de comunicação do dataset

Os subconjuntos s008 e s009 contêm 2086 e 2000 episódios, respectivamente, com apenas uma cena ou "*snapshot*" por episódio. Dentro de cada cena, os receptores podem não obter comunicação com o transmissor, diminuindo assim a quantidade de amostras em cada cena. A Figura 4.3 mostra a média de amostras por cada 100 cenas.

Por tratar-se de uma simulação realista, nestes subconjuntos se encontram dois tipos de comunicações estabelecidas entre um par Tx-Rx, LoS ou NLoS, lembrando que o tipo de conexão NLoS pode aumentar o grau de dificuldade da seleção do índice do feixe ao se tratar de um enlace de comunicação composto por múltiplos trajetos. Assim, na Tabela 4.2 estão resumidas as estatísticas gerais dos *datasets* em relação às amostras LoS e NLoS.

Dataset	# Amostras	Canais LOS	Canais NLOS
s008	11194	6482	4712
s009	9638	1473	8165

Tabela 4.2: Estatísticas dos dataset S008 e S009

Apesar destes subconjuntos estar compostos pelos dados multimodais LiDAR,




Figura 4.3: Média das amostras a cada 100 episódios

imagens de câmeras, dados de posição, e traçado de raios, para o desenvolvimento deste trabalho não foram usados os dados das imagens das câmeras. Nesse sentido, os dados de posicionamento dos veículos receptores, foram realizados através do software SUMO, e com o intuito de tornar os dados mais realistas, na simulação do posicionamento dos receptores através de coordenadas GPS, foi adicionado um ruído gaussiano independente e identicamente distribuído (*iid*). Estas informações estão compostas por:

- Val: *flag* que indica se houve estabelecimento do canal ou não. canal válido (V) ou invalido (I);
- *episodeID*: identificador para os episódios;
- *sceneID*: identificador para as cenas;
- *vehicleArrayID*: identificador para os veículos receptores;
- *vehicleName*: nome do veículo;
- coordenadas x, y, z ;
- quantidade de raios usados durante a simulação do traçado de raios,
- LOS: *flag* identificadora do tipo de conexão estabelecida entre um transmissor e um receptor LoS (*True*) NLoS (*False*).

As informações coletadas por sensores LiDAR fornecem informações 3D do ambiente através de ondas ópticas. Estes sistemas têm apresentado alta eficiência energética e maior precisão em detecção de alcance. Além disso, podem trabalhar em condições ambientais variadas (como chuva, neve e névoa), e são compactos,

tornando-se uma escolha adequada para imageamento 3D (MAKSYMOVA *et al.*, 2018) (RAJ *et al.*, 2020). Logo, neste *dataset* as informações dos dados LiDAR se encontram numa representação quantizada uniforme PCD(x,y,z) numa estrutura 4D.

E finalmente, o *dataset* oferece os dados do traçado de raios, numa estrutura 4D a qual é composta pelo numero da cena, número de pares Tx-Rx, quantidade máxima de raios, e 8 parâmetros que caracterizam cada raio, os quais são: potência recebida (dBm), tempo de chegada (segundos), angulo de elevação de partida (graus), ângulo de azimut de partida (graus), ângulo de elevação de chegada (graus), ângulo de azimut de chegada (graus), indicador se o raio é LoS ou NLoS, e a fase do raio (graus).

A partir destas informações o *dataset* oferece a matriz *Beam_output* como *baseline*, a qual representa as respostas efetivas do canal beamformed.

4.2 Pré-processamento dos dados

Para o desenvolvimento deste trabalho foram usados como dados de entrada a posição dos veículos e os dados do sensor LiDAR. Para a rotulação foi usada uma matriz conhecida no *dataset* com *Beam_output*, a qual contém a descrição do *codeword* ótimo.

4.2.1 Coordenadas

No Raymobtime, a posição dos veículos receptores são representados por valores de ponto flutuante para cada coordenada x , y e z , e conforme mencionado na subseção 2.2, o modelo da rede WiSARD exige que a entrada seja exclusivamente binária. Para atender a esse requisito, foi implementada a técnica de binarização conhecida como “termômetro”.

Essa abordagem mapeia valores contínuos para uma representação binária onde cada bit indica se o valor ultrapassou um limiar específico. O número de bits utilizados para representar o valor corresponde ao número de divisões no intervalo do dado. Esta técnica não é exclusiva deste estudo; ela também é adotada para enfrentar desafios semelhantes, como por exemplo o apresentado em (LELLO *et al.*, 2020).

Para este trabalho, o valor contínuo a codificar representa a distância relativa entre uma coordenada dada e o valor da coordenada mínima do *dataset*. Especificamente, quando a posição do receptor se alinha com a coordenada mínima (e assumindo uma resolução de 1), apenas um único bit é ativado para representar esse valor mínimo. Por outro lado, se o receptor estiver posicionado na coordenada

máxima, todos os bits dentro da codificação são ativados, conforme ilustrado na Figura 4.4. Esse processo de codificação é aplicado de forma independente às coordenadas x e y . Como resultado, a representação binária para cada coordenada varia em tamanho, capturando os relacionamentos espaciais exclusivos inerentes ao conjunto de dados.

Essa técnica não só preserva a ordem dos dados como também converte os valores contínuos de GPS em um formato binário que a rede WiSARD pode interpretar e processar com precisão.




Figura 4.4: Exemplo de pré-processamento de três valores de coordenadas na posição x . A primeira coordenada na posição mínima, a segunda na posição máxima e a terceira numa posição intermediária.

A escolha da resolução para a codificação usando a técnica do termômetro influencia diretamente a eficácia do modelo WiSARD. A resolução impacta linearmente o tamanho da entrada do modelo, tornando essencial a busca por parâmetros otimizados. Esse processo está detalhado no Anexo C, onde é explorada a influência das resoluções na precisão do modelo. Essa análise guiou a seleção de uma resolução ideal que equilibra o desempenho e a utilização de recursos computacionais. Com base nessa otimização, foram definidos como parâmetros ideais uma resolução de 8 para a codificação e o endereçamento das memórias RAM com um tamanho de 54 bits.

4.2.2 LiDAR

Originalmente, os dados LiDAR, são representados por matrizes 4D, compostas por valores -1 e -2 que representam a posição do receptor e transmissor, e os obstáculos são representados com o valor 1. Essa estrutura é ilustrada no lado direito da Figura 4.5.




Figura 4.5: Pré-processamento dos dados LiDAR. Lado esquerdo, receptor em 3D. Lado direito cenário completo quantizado

Para adequar esses dados às necessidades do modelo, foi realizada uma etapa inicial de quantização. Adicionalmente, desenvolvemos uma abordagem exclusiva de codificação termométrica tridimensional (3D), que captura a posição espacial do receptor no ambiente. Essa técnica inovadora está detalhada no lado esquerdo da Figura 4.5.

A entrada dos dados LiDAR, portanto, não inclui apenas a localização precisa do receptor, mas também um mapa abrangente que representa todos os obstáculos quantizados na cena. Para simplificar a manipulação e o processamento desses dados no modelo, transformamos a matriz tridimensional (3D) em uma representação bidimensional (2D), descartando as informações relativas à altura, como mostrado na Figura 4.6.




Figura 4.6: Pré-processamento dos dados LiDAR. Posição do receptor e cenário completo em 2D

Além da quantização, avaliamos uma técnica de filtragem baseada em limiar de variância. Este algoritmo elimina recursos que exibem baixa variabilidade, abaixo de um limiar predefinido. Portanto, primeiro foi avaliado o desempenho da WiSARD variando o tamanho do endereço da memória (*RAM size*), conforme apresentado na Figura 4.7. Após identificar que o melhor desempenho foi alcançado com um tamanho de memória de 58, cinco níveis diferentes de limiar de variância foram avaliados, como apresentados na Figura 4.8.




Figura 4.7: Avaliação de desempenho dos dados lidar 2D em função do endereçamento das memórias RAM

Os resultados revelaram que o melhor desempenho foi obtido com um limiar de 0,1. No entanto, ao utilizar um limiar de 0,15, houve uma redução de 17% no tamanho da entrada, com impacto negativo de apenas 0,39% na acurácia. Considerando esse equilíbrio entre redução da complexidade computacional e manutenção do desempenho, optamos por utilizar o limiar de 0,15 para as avaliações subsequentes.




Figura 4.8: Avaliação de desempenho do modelo WiSARD usando a técnica de limite de variância em dados LiDAR 2D

Finalmente, as duas matrizes são redimensionadas num vetor e concatenadas para criar um único vetor que encapsula a localização do receptor e as informações dos obstáculos ao redor.

4.2.3 Pós-processamento dos rótulos

Com relação aos *labels*, estes não são fornecidos diretamente pelo *dataset*. O Ray-mobtime inclui, em seus dados de *baseline*, uma matriz que descreve o *codeword* ótimo para cada enlace de comunicação. Essa matriz é calculada a partir dos dados de *ray-tracing*, que modelam o comportamento das ondas milimétricas geradas na faixa de frequência de 60 GHz em cenários *outdoor*.

Para cada par transmissor-receptor (Tx/Rx), os dados de *ray-tracing* fornecem informações detalhadas de 25 raios mais fortes. Esses raios são caracterizados por:

- Potências recebidas,
- Tempos de chegada,
- Ângulos de elevação e azimute (tanto de partida quanto de chegada),
- Ângulos de fase.

Com base nessas informações, foi calculado o subcanal MIMO para cada raio utilizando o modelo representado pela equação 2.9. Nessa configuração, assumiu-se:

- Antenas transmissoras e receptoras organizadas em arranjos lineares uniformes (*Uniform Linear Array* - ULA);
- 32 elementos na antena transmissora (Tx) e 8 na antena receptora (Rx);
- Espaçamento entre elementos de meia longitude de onda;
- *Codebooks* são gerados com base na Transformada Discreta de Fourier (DFT).

A Figura 4.9 ilustra a distribuição dos índices das 256 combinações possíveis entre os *codebooks* do transmissor e dos receptores. Esta distribuição mostra que a concentração dos feixes se encontra espalhada em pequenas faixas de índices, sendo predominante a faixa entre 150 e 160, ou seja, um *dataset* altamente desbalanceado.

No anexo D, é apresentada uma análise sobre a distribuição dos índices dos feixes com relação à posição (x,y) dos receptores, também é possível observar como é o comportamento desta distribuição entre os feixes usados pelos transmissores e receptores separadamente.




Figura 4.9: Distribuição dos índices dos feixes.

4.3 Descrição dos métodos de *baseline*

Com base na revisão apresentada na Seção 3, os trabalhos de J. Ruseckas RUSECKAS *et al.* (2021) e B. Salehi SALEHI *et al.* (2022) foram selecionados como *baseline* para avaliar a abordagem proposta. Esses trabalhos foram escolhidos porque empregaram parâmetros experimentais semelhantes ao proposto neste trabalho e relataram métricas de desempenho fortes, tornando-os adequados para comparação.

Para a entrada LiDAR, ambos os autores projetaram seus modelos com base em arquiteturas inspiradas no ResNet. No entanto, as implementações específicas diferem, conforme resumido nas Figuras 4.10 e 4.11. Essas figuras fornecem uma comparação detalhada dos modelos, destacando aspectos como tipos de camadas, número de camadas e neurônios, entre outros recursos arquiteturais.

Além disso, os principais parâmetros usados em seus experimentos, como tamanho do lote, taxa de aprendizado e épocas de treinamento, são resumidos na Tabela 4.3 para referência. Essa comparação garante uma avaliação consistente e justa dos modelos.




Figura 4.10: Modelo de rede neural usado em SALEHI *et al.* (2022) para entrada LiDAR




Figura 4.11: Modelo de rede neural usado em RUSECKAS *et al.* (2021) para entrada LiDAR

Parametros	B. Salehi	J. Ruseckas
Épocas de treinamento	100	50
Tamanho do Batch	32	32
Taxa de aprendizado	0,0001	Increase according to a coise law for the 30% of leaning duration
Otimizador	Adam β (0.9 , 0.999)	Adam β (min 0.85)
Função de ativação	Categorical cross entropy	
Total params.	2322528 (8.86 MB)	1029476 (3.93 MB)

Tabela 4.3: Parâmetros usados pelos autores do *baseline* B. Salehi SALEHI *et al.* (2022) e J. Ruseckas RUSECKAS *et al.* (2021) no modelo LiDAR

Capítulo 5

Metodologia proposta

Em sistemas de comunicação sem fio, particularmente nas bandas de ondas milimétricas (mmWave) e terahertz (THz) usadas em redes 5G e 6G, a seleção eficiente de feixes é crítica para estabelecer links de alta qualidade. Abordagens tradicionais, como busca exaustiva de feixes ou modelos pré-treinados com base em conjuntos de dados estáticos, enfrentam limitações em ambientes dinâmicos. Esses métodos geralmente não conseguem se adaptar a cenários de rápida mudança, como aqueles encontrados em ambientes veiculares ou urbanos, onde a mobilidade do usuário, obstáculos e padrões de interferência podem causar variações frequentes nas informações de estado do canal.

O aprendizado online oferece uma abordagem promissora para lidar com esses desafios, permitindo que o modelo seja atualizado incrementalmente conforme novos dados se tornam disponíveis. Essa capacidade permite que o mecanismo de seleção de feixes se adapte em tempo real às condições dinâmicas da rede, melhorando assim a robustez e a eficiência do sistema. Características tais como atualizações incrementais, onde o modelo seja atualizado a cada nova observação sem necessidade de retreinamento completo, onde a rápida adaptabilidade é crucial. Da mesma maneira, o baixo *overhead* computacional, seria extremamente útil dado que seria possível executar atualizações com atraso mínimo, atendendo a restrições de tempo real, essenciais para sistemas de comunicação sem fio.

No aprendizado supervisionado em modelos de aprendizado de máquina (ML), o objetivo principal é treinar uma função capaz de prever uma variável de saída com base em um conjunto de variáveis de entrada. Contudo, em muitos cenários práticos, obter rótulos para os dados pode ser caro ou inviável devido a restrições de tempo ou custo.

O aprendizado online oferece uma alternativa ao permitir a seleção de um subconjunto de dados para rotulagem, visando melhorar o desempenho do modelo mesmo com limitações orçamentárias para rotular observações. O principal desafio nesse contexto é decidir quais pontos serão rotulados. Para isso, existem diversas estraté-

gias que buscam equilibrar o custo da rotulagem e a qualidade do modelo, conforme apresentado na sub-sessão 2.3.

5.1 Proposta para avaliação

Para efeitos de experimentação em nível de laboratório, foi desenhada uma estratégia de avaliação online sem considerar as limitações de rotulação das novas amostras, Nesta proposta, o modelo de rede neural poderá ser retreinado com cada nova amostra, conforme apresentado na Figura 5.1. Esta metodologia é proposta com o intuito de avaliar a eficácia das técnicas de aprendizado de máquina para seleção de feixes em sistemas mmWave dinâmicos.




Figura 5.1: Diagrama de sequência ideal entre o transmissor e o receptor

Assim, foi desenvolvida uma metodologia abrangente que compara três abordagens. Se trata, de criar diferentes conjuntos de dados (janelas) para treinamento e, avaliar este modelo a cada nova amostra. Como foi mencionado no capítulo 4.1. O conjunto de dados para **teste** é o s009, este *dataset* possui 2000 episódios e cada um deles é composto por diferentes quantidades de amostras. Assim, a avaliação das métricas serão realizadas a cada episódio testado, e o resultado final, será uma média de todas as métricas calculadas individualmente. Por tanto, as janelas avaliadas são: a janela fixa, a janela incremental e a janela deslizante.

5.1.1 Abordagem de janela fixa

Neste método, uma janela de dados de tamanho fixo é usada para armazenar um conjunto de amostras de dados recentes para treinamento. O modelo é treinado neste conjunto de dados fixo e testado com cada novo evento (episódio), como mostrado na figura 5.2. Cada episódio representa um cenário distinto de conexão veicular, caracterizado por condições ambientais e de mobilidade variáveis. A acurácia é calculada para cada episódio, fornecendo *insights* sobre o desempenho do modelo em circunstâncias dinâmicas.




Figura 5.2: Representação da janela fixa

5.1.2 Abordagem de janela incremental

Nesta abordagem, o conjunto de dados de treinamento cresce incrementalmente ao longo do tempo, acumulando todos os eventos passados conforme novos dados se tornam disponíveis. Na Figura 5.3 se encontra uma representação desta proposta. Ao contrário da abordagem de janela fixa, onde apenas um conjunto limitado de amostras recentes é usado para treinamento, este método retém todo o histórico de eventos, permitindo que o modelo aproveite o conhecimento abrangente para seleção de feixes.

Embora esta abordagem seja impraticável em cenários do mundo real devido aos desafios de manter e processar um conjunto de dados em constante expansão, ela serve como um *benchmark* “ideal” neste estudo. Ao tratar todo o conjunto de dados históricos como disponível para treinamento, a abordagem de janela incremental fornece um limite superior teórico para o desempenho, oferecendo *insights* sobre o quanto o modelo poderia melhorar com conhecimento completo de eventos passados.

Nesta configuração, a precisão do modelo é avaliada após cada novo episódio. Cada episódio representa um cenário distinto, como um evento de conexão veicular, onde o modelo se beneficia de sua experiência acumulada para adaptar suas previsões de forma eficaz.

5.1.3 Abordagem de janela deslizante

Nessa abordagem, o conjunto de dados de treinamento é atualizado dinamicamente ao longo do tempo, mantendo um tamanho fixo. À medida que novos eventos são




Figura 5.3: Representação da janela incremental

adicionados, pontos de dados mais antigos são removidos, garantindo que o modelo seja sempre treinado nas informações mais recentes e relevantes. Esse mecanismo de janela deslizante permite que o conjunto de dados permaneça atualizado, refletindo a natureza dinâmica do ambiente de comunicação sem fio.

O desempenho dos modelos de aprendizado de máquina é avaliado após cada novo evento, com a precisão e outras métricas (por exemplo, taxa de transferência) sendo medidas continuamente. Isso garante que a adaptabilidade e a capacidade de resposta do modelo às mudanças de condições sejam efetivamente capturadas.

Para avaliar completamente a robustez e a eficiência dessa abordagem, variamos o tamanho do conjunto de dados de janela deslizante. Ao testar diferentes tamanhos de janela, buscamos avaliar o impacto do escopo temporal do conjunto de dados no desempenho de todos os modelos de aprendizado de máquina em consideração. Selecionamos cinco tamanhos de janela diferentes: 100, 500, 1000, 1500 e 2000 episódios, e na Figura 5.4 é representado o tamanho do conjunto de dados de treinamento 1000 como exemplo.




Figura 5.4: Representação da janela deslizante

5.2 Indicadores de desempenho

Com o intuito de medir o desempenho dos modelos, foram usados como indicadores de avaliação: acurácia, taxa de transferência (RT) e complexidade computacional.

- Acurácia é uma métrica padrão usada para avaliar o desempenho de modelos de aprendizado de máquina. Ela representa a proporção de previsões corretas em relação ao número total de previsões. Para avaliar nosso modelo, medimos a precisão em conjuntos top-k, onde k varia de 1 a 30. Aqui, o top-k se refere ao subconjunto dos melhores pares de feixes selecionados pela técnica de aprendizado de máquina.
- A Taxa de Transferência (RT) quantifica a eficiência do modelo de seleção de feixes em termos de transferência. Ela é definida como a razão entre as médias das taxas de transferência máxima obtidas dentre os pares de feixes top-k previstos pelo modelo e as taxas de transferência máxima obtidas por meio da busca exaustiva de feixes. Essa métrica indica a capacidade do modelo de reduzir o espaço de busca de feixes sem comprometer substancialmente o desempenho da comunicação. A RT é calculada usando a Equação 5.1, onde N é o número total de amostras e $\widehat{(p, q)}$ representa o par de feixes ideal para cada amostra e $\overline{(p, q)}$ o melhor par de feixes previsto pelo modelo.

$$RT = \frac{\sum_{i=1}^N \log_2(1 + y_{\widehat{(p, q)}})}{\sum_{i=1}^N \log_2(1 + y_{\overline{(p, q)}})} \quad (5.1)$$

- Complexidade Computacional. Neste estudo, o tempo de treinamento foi utilizado como uma métrica prática para avaliar a complexidade computacional. Embora não seja uma medida teórica direta, o tempo de treinamento serve como um indicador empírico do esforço computacional necessário para otimizar um modelo. É particularmente valioso para comparar arquiteturas, pois reflete as demandas de processamento do mundo real e os desafios de otimização.

O tempo de treinamento serve como uma métrica prática para avaliar a complexidade computacional, sendo significativamente influenciado por fatores como o número de parâmetros, a profundidade do modelo e a eficiência computacional da implementação. Modelos maiores ou mais complexos normalmente exigem mais iterações e operações por época, levando a maiores tempos de treinamento.

As especificações de hardware também desempenham um papel fundamental na determinação do tempo de treinamento. Para garantir consistência e repro-

reprodutibilidade, todos os experimentos foram conduzidos em uma máquina virtual configurada com as seguintes especificações: sistema operacional Ubuntu 22.04.3 LTS, versão do kernel 5.15.0-124-generic, 8 núcleos de CPU e 64 GB de RAM.

O tempo de treinamento foi registrado em segundos, oferecendo uma métrica padronizada e interpretável para comparar a complexidade computacional de diferentes arquiteturas de modelos. Essa abordagem permite uma avaliação justa das demandas computacionais do mundo real associadas a cada método.

Capítulo 6

Resultados parciais e discussões

6.1 Desempenho da rede WiSARD

Com o intuito de avaliar o desempenho da rede WiSARD a partir do tipo de comunicação estabelecida, podendo ser esta, com linha de visado (LOS) ou sem linha de visado (NLOS), o *dataset* foi filtrado considerando essas condições específicas. Na figura 6.1, é possível observar uma comparação de desempenho da rede WiSARD entre os tipos de comunicação utilizando os dados das coordenadas, os dados LiDAR e os dados multimodais (coordenadas + LiDAR).




Figura 6.1: Comparação de desempenho da rede WiSARD, com diferentes entradas e tipos de comunicação

Como é esperado, em todos os casos a comunicação LOS proporciona um desempenho superior, devido ao canal de comunicação predominantemente desobstruído. A ausência de obstáculos ou dispersores reduz a variabilidade das condições do canal, permitindo que algoritmos de seleção de feixe, como os baseados em WiSARD, operem com maior acurácia. Em contraste, cenários NLOS envolvem reflexões, difrações e espalhamento, que degradam a qualidade do sinal recebido com um comporta-

mento, o que dificulta a otimização do feixe e pode introduzir erros no mapeamento realizado pelo modelo.

Essas análises evidenciam que a rede WiSARD explora eficientemente as características dos cenários LOS para maximizar o desempenho. No entanto, é mostrado, também uma robustez considerável em condições adversas de NLOS. Esse comportamento destaca sua adequação para aplicações em ambientes variados, como comunicações veiculares e redes urbanas densas.

6.2 Comparação convencional dos modelos

Conforme descrito na seção 4.1, os subconjuntos s008 e s009 do *dataset* Raymobtime foram utilizados para a avaliação. Com o intuito de garantir uma comparação justa, foi usada a mesma metodologia empregada nos trabalhos de referência. Especificamente, os modelos foram treinados com os dados do subconjunto s008 e avaliados com os dados do subconjunto s009. Na Figura 6.2 é apresentada uma representação desta avaliação. Essa estratégia assegura medições consistentes e facilita a comparação de métricas fundamentais, como acurácia, taxa de transferência (*throughput ratio*) e tempo de processamento.




Figura 6.2: Diagrama de sequência de uma avaliação tradicional

Nesta comparação, foram utilizadas diferentes abordagens para as entradas dos modelos, incluindo dados unimodais (coordenadas ou LiDAR) e dados multimodais (combinação entre as coordenadas e os dados LiDAR).

De maneira geral, o desempenho da rede WiSARD mostrou-se competitivo tanto para a métrica de acurácia (Figura 6.3) quanto para a métrica de taxa de transferência (Figura 6.4) em comparação com as topologias de *baseline*. Destaca-se que, no caso mais desafiador (top k=1), o modelo WiSARD, ao utilizar entradas LiDAR, superou em 11,9% o modelo de Salehi et al. SALEHI *et al.* (2022) e em 3,3% o

modelo de Ruseckas et al. RUSECKAS *et al.* (2021). Quando os dados multimodais foram utilizados como entrada, a rede WiSARD alcançou melhorias ainda mais expressivas, com um aumento de 17,49% e 1,29%, respectivamente.




Figura 6.3: Comparação de desempenho de acurácia entre o modelo proposto WiSARD e as técnicas de aprendizado de maquina propostas pelos autores SALEHI *et al.* (2022), e RUSECKAS *et al.* (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).




Figura 6.4: Comparação de desempenho de *throughput ratio* entre o modelo proposto WiSARD e as técnicas de aprendizado de maquina propostas pelos autores SALEHI *et al.* (2022), e RUSECKAS *et al.* (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).

Devido à consistência e desempenho em termos de acurácia do modelo WiSARD, a eficiência computacional foi avaliada medindo o tempo de treinamento em cada modelo e tipo de entrada. Os resultados resumidos nas Figuras 6.5 e 6.6, as quais confirmam a natureza leve da abordagem WiSARD para seleção de feixes, pois esta técnica demonstra ser 99,78% mais rápida quando comparado com os modelos de

base, tornando-o uma escolha altamente eficiente. Para esta avaliação, foi usada uma máquina com um processador M1 Pro, de 16 Gb de memória RAM e um sistema operacional macOS ventura versão 13.67.




Figura 6.5: Comparação dos tempos de treinamento entre o modelo proposto e as técnicas de aprendizado de maquina da literatura dos autores SALEHI *et al.* (2022), e RUSECKAS *et al.* (2021) usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).




Figura 6.6: Desempenho da rede WiSARD em tempos de treinamento usando as entradas unimodais (coordenadas e dados LiDAR) e multimodais (coordenadas + LiDAR).

6.3 Comparação dos modelos usando a metodologia proposta

6.3.1 Janela fixa

Para cada tipo de entrada - coordenadas, LiDAR e coordenadas + LiDAR - foi avaliado o desempenho dos modelos em termos de acurácia, *throughput ratio* e tempo de treinamento.

Sob a abordagem de **Janela Fixa**, foi realizada uma avaliação em termos de acurácia dos três modelos de ML. Na Tabela 6.1, é apresentada a acurácia top-1 alcançada por cada modelo a partir das entradas unimodais e multimodais. Os resultados evidenciam que todos os modelos conseguem aprimorar seu desempenho quando dados multimodais são usados. No entanto, o desempenho da rede WiSARD se mostrou consistente, com um desempenho superior aos modelos de comparação.

Ref	Coord	LiDAR	Coord + LiDAR
B. Salehi	0,145	0,464	0,5
J. Ruseckas	0,607		
WiSARD	0,585	0,581	0,606

Tabela 6.1: Comparação de desempenho da acurácia top-1 dos modelos proposto por J. Ruseckas RUSECKAS *et al.* (2021), B. Salehi SALEHI *et al.* (2022) e a proposta da rede WiSARD, para a abordagem de janela fixa.

A Figura 6.7 ilustra o desempenho da acurácia top-k das abordagens propostas por Salehi, Ruseckas e WiSARD, usando LiDAR como dados de entrada. É evidente que o desempenho da WiSARD para as condições top-1 é superior em 12%, já para top-k onde $k > 10$, este desempenho diminui no pior caso em 0.03% quando comparado com os outros modelos.

Com o intuito de avaliar o desempenho top-k da rede WiSARD usando entradas unimodais e multimodais, a Figura 6.8 destaca o desempenho de precisão do modelo WiSARD ao usar como dados de entrada: coordenadas, LiDAR e coordenadas + LiDAR. Observamos que, em geral, o modelo WiSARD demonstra desempenho consistente em todos os tipos de entrada. O modelo alcançou pontuações de acurácia semelhantes com coordenadas e entradas LiDAR, enquanto o uso de dados multimodais (coordenadas + LiDAR) levou a uma melhoria de 3,4% na precisão.

Em termos de complexidade computacional, os experimentos destacam características-chave da rede neural WiSARD, particularmente sua arquitetura leve e eficiência computacional. Isso permite tempos de treinamento mais rápidos, conforme demonstrado na Tabela 6.2, onde o modelo WiSARD superou significativamente as técnicas de *baseline* em termos de tempo de treinamento. Esta tabela




Figura 6.7: Abordagem de Janela fixa. Comparação de desempenho top-k com dados LiDAR entre as técnicas avaliadas

apresenta as principais medidas estatísticas dos resultados. Dadas as diferenças significativas nos tempos de treinamento, é reportado o primeiro quartil (Q_1), segundo quartil ou mediana (Q_2), e terceiro quartil (Q_3), representando os valores mínimo, médio e máximo, respectivamente.

Input	Ref	Train Time [seg]					
		Min	Mean	Max	(Q_1)	(Q_2)	(Q_3)
Coord	B. Salehi	36,579	44,827	51,344	43.682	44.039	44.565
	J.Ruseckas	19,274	20,356	23,572	19.904	20.096	20.336
	WiSARD	0,414	0,421	0,466	0,419	0,421	0,422
LiDAR	B. Salehi	1086	1103	1121	1100	1103	1107
	J.Ruseckas						
	WiSARD	0,214	0,218	0,241	0,216	0,217	0,218
Coord + LiDAR	B. Salehi	1277	1284	1289	1279	1285	1287
	J.Ruseckas						
	WiSARD	0,649	0,666	0,728	0,663	0,665	0,668

Tabela 6.2: Comparação de estatísticas de tempo de treinamento para janela fixa entre o modelo WiSARD e os modelo de *baseline*




Figura 6.8: Abordagem janela fixa. Comparação de desempenho da rede WiSARD com entradas coordenadas, LiDAR, e coordenadas + LiDAR.

6.3.2 Janela deslizante

Como foi descrito anteriormente, foram avaliados cinco tamanhos de janela diferentes: 100, 500, 1.000, 1.500 e 2.000 episódios. O tamanho máximo de 2.000 foi selecionado devido às limitações de tamanho inerentes ao conjunto de dados. A Figura 6.9 ilustra as tendências de desempenho da rede WiSARD conforme o tamanho da janela varia usando como coordenadas.

Os resultados indicam que janelas maiores geralmente melhoram a precisão, pois o modelo se beneficia de um conjunto de dados mais abrangente que captura diversas condições ambientais. No entanto, esta melhoria tem o custo de um maior tempo médio de treino, uma vez que o processamento de um conjunto de dados maior requer mais esforço computacional. Por outro lado, janelas menores permitem atualizações mais rápidas do modelo, permitindo maior adaptabilidade a condições que mudam rapidamente, mas à custa de uma precisão ligeiramente reduzida.

Como esperado, o tempo médio de treinamento aumenta conforme o tamanho da janela. Porém, são observadas variações notáveis na distribuição do tempo de treinamento, influenciadas pelo número de amostras dentro de cada episódio, conforme apresentado na Figura 4.3, onde é notório que o o conjunto de dados s008 contém, em média, um maior número de amostras por episódio. Como resultado deste aumento de informação, as distribuições dos tempos de treinamento torna-se mais dispersas, de acordo com o resultado deste experimento apresentado na Figura 6.10.

Estas observações reforçam a importância de equilibrar cuidadosamente o tama-




Figura 6.9: Desempenho da rede WiSARD variando os tamanhos das janelas usando coordenadas

nho da janela para otimizar a precisão e a eficiência computacional, dependendo das restrições de tempo real da aplicação.

Descobrimos que 1000 episódios é o tamanho de janela ideal para o conjunto de treinamento. Este valor foi calculado a partir de uma função de penalidade. Para esta função foi considerado um percentual para cada métrica distribuído com 60% para acurácia e 40% para tempo de treinamento. A função de penalidade é $acuracia \cdot \beta - tempo\ de\ treinamento \cdot \alpha$, onde $\beta = 0,6$ e $\alpha = 0,4$. Assim os modelos de *baseline* também foram avaliados com tamanhos de janelas 1000 e na Tabela 6.3 é mostrado o desempenho da acurácia top-1 usando dados de entrada unimodal e multimodal.

Ref	Coord	LiDAR	Coord + LiDAR
B. Salehi	0,178	0,494	0,481
J. Ruseckas			
WiSARD	0,619	0,61	0,62

Tabela 6.3: Comparação de desempenho top-1 dos modelos J. Ruseckas RUSECKAS *et al.* (2021), B. Salehi SALEHI *et al.* (2022) e modelo proposto WiSARD, para uma abordagem de janela deslizante, com tamanho de janela = 1000 episódio para treinamento.




Figura 6.10: Comparação dos tempos de treinamento para diferentes tamanhos de janelas usando uma abordagem de janela incremental e coordenadas como entrada

6.3.3 Janela incremental

Esta abordagem apresenta diversas vantagens em cenários onde os dados chegam de forma contínua e o modelo precisa se adaptar dinamicamente. Esta proposta permite que o modelo capture padrões complexos e aprimore continuamente suas previsões. Em tarefas onde a distribuição dos dados varia ao longo do tempo (não estacionários), essa abordagem pode ser útil para detectar tendências de longo prazo. Como o modelo é atualizado com um conjunto crescente de exemplos, ele tende a apresentar uma melhor capacidade de generalização ao aprender com um volume maior de dados. Isso pode reduzir problemas como *overfitting*, que ocorre quando o modelo se ajusta demais a um conjunto de treinamento pequeno. Todas estas vantagens fazem desta abordagem o *benchmark* ideal e podem se ver refletido nos resultados das simulações, como mostrado na Tabela 6.4, onde pode ser observada a comparação top-1 da acurácia para todas as técnicas avaliadas.

Ref	Coord	LiDAR	Coord + LiDAR
B. Salehi	0,20	0,574	
J. Ruseckas			
WiSARD	0,633	0,634	0,64

Tabela 6.4: Comparação de desempenho acurácia top-1 dos modelos J. Ruseckas RUSECKAS *et al.* (2021), B. Salehi SALEHI *et al.* (2022) e WiSARD, usando na abordagem de janela incremental.

Na Figura 6.11, é possível evidenciar o desempenho da rede WiSARD quando são usados dados unimodais e multimodais. Nesta comparação, podemos observar que esta técnica, consegue manter sua precisão de forma consistente com relação ao tipo de dado de entrada.




Figura 6.11: Abordagem Janela incremental. Desempenho da rede WiSARD com entradas unimodais e multimodais.

6.3.4 Janela deslizante saltitante

Com o intuito de adaptar a metodologia proposta de abordagem online a um cenário mais realista do *dataset* Raymobtime, especificamente dos subconjuntos s008 e s009, é importante considerar que nestes *dataset* a coleta de dados foi feita a cada 30 segundos.

Então, isso significa que, se idealmente a técnica de ML puder treinar um novo modelo num tempo inferior a 30 segundos, este modelo poderia ter uma resposta a mudanças rápidas no ambiente.

No entanto, como podemos ver na Tabela 6.2, o tempo de treinamento para modelos de redes neurais profundas é muito maior. Devido a isso, procurou-se criar uma atualização do modelo DNN para que ele responda o mais rápido possível ante possíveis mudanças no ambiente. Diante deste cenário, a partir da abordagem de janela fixa, onde os experimentos mostraram um tempo médio de treinamento de 1103 segundos para o modelo apresentado por SALEHI *et al.* (2022) é possível concluir que o modelo poderia ser re-treinado aproximadamente a cada 37 episódios. Na Tabela 6.5 é apresentado o desempenho do modelo proposto por SALEHI *et al.* (2022)

Top-k	1	5	10	15	20	25	30
Acurácia	0,436	0,822	0,891	0,926	0,947	0,959	0,967

Tabela 6.5: Desempenho do modelo proposto por SALEHI *et al.* (2022) usando dados LiDAR na abordagem janela saltitante deslizante.

6.3.5 Análise de desempenho da metodologia proposta na rede WiSARD

Com o intuito de comparar o desempenho da rede WiSARD nas diferentes abordagens de aprendizado online propostas, a Figura 6.12 apresenta as acurácias top-K alcançadas pela rede neural sem peso, considerando dados de entrada unimodais e multimodais.




Figura 6.12: Comparação de desempenho da rede WiSARD nas abordagens propostas de aprendizado *on-line* usando os dados das coordenadas.

De modo geral, os resultados das simulações indicam que a rede WiSARD manteve um desempenho consistente em relação ao tipo de entrada utilizado.

Ao empregar a estratégia de janela incremental, conforme esperado, a rede WiSARD obteve a maior acurácia. Isso ocorre porque, nessa abordagem, o modelo aprende a partir de um histórico completo das dinâmicas do ambiente, o que representa um cenário ideal para qualquer técnica de aprendizado de máquina. No entanto, essa condição se torna inviável em aplicações reais, pois exigiria dispositivos com capacidade de armazenamento e processamento praticamente ilimitada à medida que o tempo avança.

A abordagem de janela fixa apresentou um desempenho muito semelhante ao do treinamento em *batch*. Nesse experimento, essa estratégia foi utilizada como *baseline*, uma vez que, ao longo da simulação, o modelo nunca é atualizado.

Por fim, do ponto de vista da acurácia, a estratégia de janela deslizante demonstrou um desempenho intermediário entre as duas abordagens anteriores. No entanto, quando analisamos o tempo de treinamento, observam-se diferenças significativas entre os métodos. A Figura 6.13 ilustra essa comparação.

Fica evidente que a janela incremental requer mais tempo de treinamento, pois a quantidade de dados processados cresce linearmente ao longo do tempo. Em contrapartida, a abordagem de janela fixa mantém constante a quantidade de amostras




Figura 6.13: Comparação dos tempos de treinamento da rede WiSARD nas abordagens propostas de aprendizado *on-line* usando os dados das coordenadas

utilizadas no treinamento, resultando em variações mínimas no tempo de processamento. Já na estratégia de janela deslizante, cujo tamanho foi definido como 1000 episódios, observa-se que a janela se desloca conforme novas amostras são recebidas. Como cada episódio contém um número variável de amostras, essa variabilidade é refletida na distribuição apresentada na Figura 6.13.

Com base nesses resultados, conclui-se que o uso de uma janela deslizante pode representar uma estratégia promissora para a seleção de feixe em redes celulares de ondas milimétricas. Ao longo das simulações realizadas, essa abordagem demonstrou alto desempenho em termos de acurácia com um volume reduzido de dados para inferência, resultando, consequentemente, em maior eficiência no tempo de treinamento.

Capítulo 7

Conclusões

7.1 Conclusões parciais

Ao longo deste trabalho, foi avaliado o uso das redes neurais WiSARD dentro do contexto de seleção de feixe.

Inicialmente, foi apresentada uma revisão bibliográfica abrangente e detalhada sobre as técnicas mais recentes empregadas na seleção de feixe. Essa revisão permitiu a comparação das configurações adotadas pelos autores, das técnicas utilizadas e dos resultados alcançados, proporcionando uma visão clara do estado da arte neste tema.

Além disso, foi proposta uma metodologia de parametrização otimizada para o uso da rede WiSARD em tarefas de classificação voltadas à seleção de feixe. Essa abordagem foi explorada considerando entradas unimodais e multimodais, além de uma análise do desempenho consistente da WiSARD em cenários de LoS e NLoS.

Também foi realizada uma comparação rigorosa entre a técnica proposta e duas abordagens representativas da literatura. Os resultados de simulação demonstraram que, no cenário mais desafiador (top-k=1), a rede WiSARD, utilizando entradas LiDAR, superou o modelo de Salehi em 11,9% e o modelo de Ruseckas em 3,3%. Além disso, a avaliação do tempo de treinamento evidenciou a leveza computacional da abordagem WiSARD, tornando o processo em média 205 vezes mais rápido em comparação às técnicas analisadas.

Dessa forma, foi proposta uma abordagem inicial de aprendizado *on-line* para a seleção de feixe em sistemas de ondas milimétricas. Os resultados parciais indicam que a WiSARD mantém um desempenho competitivo em relação às técnicas baseadas em aprendizado profundo, ao mesmo tempo em que apresenta alta eficiência em termos de tempo de treinamento. O mecanismo de aprendizado da WiSARD se mostra adequado para o aprendizado *on-line*, pois possibilita aprendizado incremental com baixos custos computacionais.

Além disso, a simplicidade de implementação da WiSARD favorece sua execução

em dispositivos com restrições de hardware e energia, tornando-a uma alternativa vantajosa em comparação aos modelos de redes neurais profundas. Essa abordagem também facilita o uso de informações de contexto, como dados de posicionamento e características ambientais, para aprimorar a seleção de feixe.

Por fim, a escolha eficiente do feixe para a transmissão de dados pode contribuir para a redução do consumo de energia em dispositivos móveis inteligentes, reforçando a relevância dessa pesquisa para o desenvolvimento de sistemas de comunicação mais sustentáveis e eficazes.

7.2 Artigos publicados

Ao longo desta pesquisa, tem-se apresentado as seguintes contribuições à comunidade acadêmica, na publicação dos seguintes artigos:

- Brilhante, D., Manjarres, J., Moreira, R., de Oliveira Veiga, L., Rezende, J., Müller, F., Klautau, A., Leonel M., Figueiredo, F. “A Literature Survey on AI-Aided Beamforming and Beam Management for 5G and 6G System”, *Sensors*, v.23, n. 9, pp. 4359, 2023.
- Manjarres, J., Cardoso, D., Klautau, A., de Rezende, J., “A WiSARD Network Approach for 5G MIMO Beam Selection”. In: *International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems*, pp. 360-373. Springer, 2024.

Capítulo 8

Proposta de tese

Ao longo deste trabalho, na seleção de feixe, as Redes Neurais Sem Peso (RNSPs) têm demonstrado um desempenho comparável a técnicas baseadas em aprendizado profundo, como redes neurais convolucionais e redes feedforward. No entanto, a natureza leve das RNSPs tem permitido sua exploração em aplicações de aprendizado on-line para seleção de feixes em ondas milimétricas, tornando-as uma alternativa viável para cenários dinâmicos.

Devido a isso, a primeira fase para a continuidade deste trabalho consiste em aprofundar a avaliação do desempenho das RNSPs em cenários dinâmicos, isso inclui a análise comparativa com abordagens tradicionais de aprendizado profundo, considerando métricas como acurácia e custo computacional. Os próximos passos são:

- i) Finalizar a implementação e avaliação dos modelos de *baseline* na abordagem *on-line* proposta até agora, garantindo uma comparação mais abrangente com a metodologia proposta.
- ii) Avaliar o desempenho de um algoritmo de RNSP para aprendizado *on-line*, comparando sua eficácia com outras abordagens de aprendizado de máquina na seleção de feixe.
- iii) Redação e publicação de um artigo apresentando o desempenho da RNSP dentro da abordagem de aprendizado *on-line* para seleção de feixe em um cenário de redes veiculares, utilizando dados sintéticos do dataset Raymobtime, conforme proposto neste documento de qualificação. O artigo também incluirá uma comparação com técnicas *baseline* tradicionais.

A partir desta primeira fase, tem-se considerado alguns enfoques como possíveis próximos passos deste trabalho, ele foram classificados nas abordagens de modelagem e simulação, experimental e incorporação de superfícies inteligentes.

8.1 Modelagem e simulação

Nesta abordagem, propõe-se a geração de novos dataset, com o intuito de criar cenários que possuam maiores correlações de temporalidade, assim como também a criação de cenários diversificados como por exemplo o aumento ou diminuição da densidade de receptores. A partir deste grau de liberdade na geração dos datasets, será possível realizar análises não apenas de estabelecimento de canal mas também a manutenção do mesmo ante ambientes dinâmicos. Esta abordagem sugere:

- i) Criação de novos dataset.
- ii) Implementação de um modelo *on-line* para seleção de feixe baseado na RNSP.
- iii) Treinamento e validação do modelo usando conjuntos de dados sintéticos próprio.
- iv) Comparação de desempenho com técnicas convencionais de aprendizado de máquina online.
- v) Escrita e publicação de um artigo que apresente o desempenho da RNS para a seleção de feixe com dados sintéticos próprios, assim como uma comparação com técnicas de *baseline*.

Contudo, esta proposta envolve dependências de acesso de licenças de softwares especializados, como por exemplo o wireless insite (encarregado da simulação do comportamento físico dos raios).

Contribuição esperada: Desenvolvimento de novos dataset como contribuição para a comunidade acadêmica, assim como, o desenvolvimento de uma abordagem de aprendizado *on-line* baseado em RNSP para seleção de feixe em sistemas mmWave, com análise comparativa em relação a abordagens convencionais.

8.2 Avaliação experimental

Nesta abordagem, tem-se levado em consideração uma das maiores características das RSNPs, a leveza do modelo, tornado-o um forte candidato em sistemas com recursos limitados como apresentado no trabalho de MIRANDA *et al.* (2022) onde foi mostrada a implementação de uma RNSP nas tecnologias FPGA e ASIC para ilustrar sua adequação para inferência de borda. Assim, pretende-se analisar a viabilidade prática da RNSP para implementação em dispositivos embarcados ou de baixo consumo energético. Nesta abordagem é proposto:

- i) Exploração de abordagens que possibilitem a implementação eficiente em hardware, garantindo um bom desempenho na seleção de feixe, com foco na viabilidade em dispositivos com recursos limitados.
- ii) Implementação do modelo RNSP em um hardware compatível (e.g., FPGA, Raspberry Pi ou outro dispositivo de baixo consumo).
- iii) Testes de desempenho em um ambiente controlado para validar a viabilidade prática da abordagem.
- iv) Integrar o uso de dados reais de sensores LiDAR. Este objetivo é compreendido dentro do marco do projeto Brasil 6G, o qual busca realizar coletas de dados em ambientes reais através de sensores LiDAR e integrá-los como informação de contexto para a seleção de feixe usando uma RNSP.
- v) Produção de um artigo que apresente o desempenho da RNSP em dispositivos com restrições de hardware com uso de dados reais LiDAR.

Contribuição esperada: Validação experimental da aplicação de uma RNSP em hardware, destacando sua aplicabilidade para dispositivos com restrições computacionais.

8.3 Incorporação de técnicas RIS

As bandas mmWave sofrem alta perda de caminho em comparação com as frequências sub-6 GHz, tornando-as aplicáveis principalmente para cenários de comunicação de curto alcance e ambientes internos. Para mitigar esse desafio, uma abordagem promissora em redes sem fio de próxima geração (B5G/6G) são os Ambientes de Rádio Inteligentes (IRS - Intelligent Radio Surfaces), onde os canais de propagação entre transmissores e receptores podem ser controlados ativamente.

Entre as soluções emergentes, as Superfícies Inteligentes Reconfiguráveis (RIS - Reconfigurable Intelligent Surfaces) têm se destacado como uma alternativa de baixo custo e alta eficiência energética. RISs são compostas por elementos passivos ou semi-passivos que ajustam dinamicamente os coeficientes de reflexão para moldar os sinais multipercursos, permitindo melhorar a cobertura e a qualidade da comunicação em cenários NLOS (Non-Line-of-Sight). Este trabalho propõe:

- i) Investigar o impacto das RISs na seleção de feixe, propondo técnicas de aprendizado de máquina para otimizar a interação entre feixes ativos e reflexivos em cenários NLOS.

- ii) Desenvolver de um framework para modelar a influência da RIS na seleção de feixe.
- iii) Implementar algoritmos baseados em RNSP para o uso da RIS na seleção de feixe.
- iv) Testes para avaliar o ganho de desempenho ao integrar RIS ao modelo WiSARD.
- v) Publicação de um artigo sobre o impacto das RISs na seleção de feixe em redes veiculares, avaliando seu desempenho em cenários NLOS.

Contribuição esperada: Exploração do impacto das RISs na formação de feixes mmWave, investigando sua aplicação para otimização dinâmica de feixes em redes 6G.

Referências Bibliográficas

ZAIDI, A., ATHLEY, F., MEDBO, J., et al. *5G Physical Layer: principles, models and technology components*. Academic Press, 2018.

LASSE, L. P. “ITU Artificial Intelligence/Machine Learning in 5G Challenge”. 2020. Disponível em: <<https://ai5gchallenge.ufpa.br/>>.

SALEHI, B., REUS-MUNS, G., ROY, D., et al. “Deep learning on multimodal sensor data at the wireless edge for vehicular network”, *IEEE Transactions on Vehicular Technology*, v. 71, n. 7, pp. 7639–7655, 2022.

RUSECKAS, J., MOLIS, G., BOGUCKA, H. “MIMO beam selection in 5G using neural networks”, *International Journal of Electronics and Telecommunications*, v. 67, n. 4, 2021.

CISCO. *Cisco Annual Internet Report prevê que 5G será responsável por mais de 10 das conexões móveis no mundo em 2023*. Relatório técnico, Cisco Brasil, 2020. Disponível em: <https://news-blogs.cisco.com/americas/pt/2020/02/19/cisco-annual-internet-report-preve-que-5g-sera-responsavel-por-mais-de-10-?utm_source=chatgpt.com>.

RUSSAKOVSKY, O., DENG, J., SU, H., et al. “Imagenet large scale visual recognition challenge”, *International journal of computer vision*, v. 115, pp. 211–252, 2015.

SUSSKIND, Z., ARORA, A., MIRANDA, I. D., et al. “Weightless neural networks for efficient edge inference”. In: *Proceedings of the International Conference on Parallel Architectures and Compilation Techniques*, pp. 279–290, 2022.

ALEKSANDER, I., DE GREGORIO, M., FRANÇA, F. M. G., et al. “A brief introduction to weightless neural systems.” In: *ESANN*, pp. 299–305. Citeseer, 2009.

- DAHLMAN, E., PARKVALL, S., SKOLD, J. *5G NR: The next generation wireless access technology*. Academic Press, 2020.
- AGIWAL, M., ROY, A., SAXENA, N. “Next generation 5G wireless networks: A comprehensive survey”, *IEEE communications surveys & tutorials*, v. 18, n. 3, pp. 1617–1655, 2016.
- MOHAMED, K. S., ALIAS, M. Y., ROSLEE, M., et al. “Towards green communication in 5G systems: Survey on beamforming concept”, *IET Communications*, v. 15, n. 1, pp. 142–154, 2021.
- BRILHANTE, D. D. S., MANJARRES, J. C., MOREIRA, R., et al. “A Literature Survey on AI-Aided Beamforming and Beam Management for 5G and 6G Systems”, *Sensors*, v. 23, n. 9, pp. 4359, 2023.
- HAMPTON, J. R. *Introduction to MIMO communications*. Cambridge university press, 2013.
- HE, S., WANG, J., HUANG, Y., et al. “Codebook-based hybrid precoding for millimeter wave multiuser systems”, *IEEE Transactions on Signal Processing*, v. 65, n. 20, pp. 5289–5304, 2017.
- FRANÇA, F., DE GREGORIO, M., LIMA, P., et al. “Advances in weightless neural systems”. In: *European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*, pp. 497–504, 2014.
- LUDERMIR, T. B., CARVALHO, A. C. P. D. L. F., BRAGA, A. P., et al. “Weightless neural models: a review of current and past works”, *Neural Computing Surveys*, v. 2, pp. 41–61, 1999.
- NAPOLI, O. O., DE ALMEIDA, A. M., BORIN, E., et al. “Memory-efficient DRASiW Models”, *Neurocomputing*, v. 610, pp. 128443, 2024. ISSN: 0925-2312. doi: <https://doi.org/10.1016/j.neucom.2024.128443>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0925231224012141>>.
- BROYLES, D., HAYNER, C. R., LEUNG, K. “Wisard: A labeled visual and thermal image dataset for wilderness search and rescue”. In: *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 9467–9474. IEEE, 2022.
- ALEKSANDER, I., THOMAS, W., BOWDEN, P. “WISARD: a radical step forward in image recognition”, *Sensor review*, v. 4, n. 3, pp. 120–124, 1984.

- KIM, H., AHN, E., CHO, S., et al. “Comparative analysis of image binarization methods for crack identification in concrete structures”, *Cement and Concrete Research*, v. 99, pp. 53–61, 2017.
- HE, J., DO, Q., DOWNTON, A. C., et al. “A comparison of binarization methods for historical archive documents”. In: *Eighth International Conference on Document Analysis and Recognition (ICDAR'05)*, pp. 538–542. IEEE, 2005.
- SAHA, S. “An analytical study of different document image Binarization methods”. In: *IEEE Natl Conf Comput Commun Syst*, pp. 71–74, 2009.
- ARRUDA, A. W. A. D. “Binarização de Imagens de Documentos Históricos Baseada em Imagem de Contraste”, 2014.
- LELLO, G. C. D., CALDEIRA, J. F., AREDES, M., et al. “Weightless Neural Networks Applied to Nonintrusive Load Monitoring”. In: *2020 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*, pp. 844–851, maio 2020.
- BACELLAR, A. T., SUSSKIND, Z., BRETERNITZ JR, M., et al. “Differentiable weightless neural networks”, *arXiv preprint arXiv:2410.11112*, 2024.
- GRIECO, B. P., LIMA, P. M., DE GREGORIO, M., et al. “Producing pattern examples from “mental” images”, *Neurocomputing*, v. 73, n. 7-9, pp. 1057–1064, 2010.
- BHARGAVI, K., JYOTHI, S. “A survey on threshold based segmentation technique in image processing”, *International Journal of Innovative Research and Development*, v. 3, n. 12, pp. 234–239, 2014.
- KAPPAUN, A., CAMARGO, K., RANGEL, F., et al. “Evaluating binary encoding techniques for wisard”. In: *2016 5th Brazilian Conference on Intelligent Systems (BRACIS)*, pp. 103–108. IEEE, 2016.
- CODA, G., DE GREGORIO, M., SORGENTE, A., et al. “Improving the DRASiW performance by exploiting its own “Mental Images””. In: *31st European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning, Bruges, Belgium*, pp. 363–368, 2023.
- DO NASCIMENTO, D. N., FRANÇA, F. M. “Object modeling through weightless tracking”, *Neural Computing and Applications*, v. 36, n. 17, pp. 10257–10278, 2024.

- DA SILVA, I. P., DOS SANTOS, J. G., NERY, A. S. “A Collaborative Weightless Neural Network”. In: *2021 Workshop on Communication Networks and Power Systems (WCNPS)*, pp. 1–5, 2021. doi: 10.1109/WCNPS53648.2021.9626292.
- SHAH, R., BALAJI, P. A., SUGUMARAN, V., et al. “Weightless Neural Network-Based Fault Diagnosis in Suspension System.” *FME Transactions*, v. 52, n. 1, 2024.
- CARDOSO, D., DE GREGORIO, M., LIMA, P., et al. “A weightless neural network-based approach for stream data clustering”. In: *Intelligent Data Engineering and Automated Learning-IDEAL 2012: 13th International Conference, Natal, Brazil, August 29-31, 2012. Proceedings 13*, pp. 328–335. Springer, 2012.
- RAMOS, L. C. S. *MALWARE CLASSIFICATION SYSTEM USING WEIGHTLESS NEURAL NETWORKS*. Tese de Doutorado, Universidade Federal do Rio de Janeiro, 2021.
- DE GREGORIO, M., GIORDANO, M. “Cloning DRASiW systems via memory transfer”, *Neurocomputing*, v. 192, pp. 115–127, 2016.
- CARDOSO, D. D. O., LIMA, P. M., DE GREGORIO, M., et al. “Clustering data streams with weightless neural networks.” In: *ESANN*, 2011.
- GRIECO, B., LIMA, P., DE GREGORIO, M., et al. “Extracting fuzzy rules from “mental” images generated by modified WiSARD perceptrons”. In: *Proc. E*, v. 26, pp. 101–773, 2008.
- SHAH, O. R., SRIDHARAN, N. V., RAMASAMY, S. N., et al. “Monitoring the condition of monoblock centrifugal pumps using vibration analysis and WiSARD classifier”, *Journal of the Brazilian Society of Mechanical Sciences and Engineering*, v. 47, n. 1, pp. 1–15, 2025.
- DE SOUZA, D. F., CARNEIRO, H. C., FRANÇA, F. M., et al. “Rock-paper-scissors WiSARD”. In: *2013 BRICS Congress on Computational Intelligence and 11th Brazilian Congress on Computational Intelligence*, pp. 178–182. IEEE, 2013.
- DE GREGORIO, M., DI COSTANZO, A., MOTTA, A., et al. “Classification of preclinical markers in Alzheimer’s disease via WiSARD classifier.” In: *ESANN*, 2022.

- MIRANDA, I. D., ARORA, A., SUSSKIND, Z., et al. “LogicWiSARD: Memoryless Synthesis of Weightless Neural Networks”. In: *2022 IEEE 33rd International Conference on Application-specific Systems, Architectures and Processors (ASAP)*, pp. 19–26, 2022. doi: 10.1109/ASAP54787.2022.00014.
- VILLON, L. A., SUSSKIND, Z., BACELLAR, A. T., et al. “A conditional branch predictor based on weightless neural networks”, *Neurocomputing*, v. 555, pp. 126637, 2023.
- FORECHI, A., DE SOUZA, A. F., OLIVEIRA NETO, J. D., et al. “Fat-Fast VG-RAM WNN: A high performance approach”, *Neurocomputing*, v. 183, pp. 56–69, mar. 2016.
- LYRIO, L. J., OLIVEIRA-SANTOS, T., BADUE, C., et al. “Image-based mapping, global localization and position tracking using VG-RAM weightless neural networks”. In: *2015 IEEE international conference on robotics and automation (ICRA)*, pp. 3603–3610. IEEE, 2015.
- SPALENZA, M. A., DE OLIVEIRA, E., LUSQUINO-FILHO, L., et al. “Using ner+ ml to automatically detect fake news”. In: *International Conference on Intelligent Systems Design and Applications*, pp. 1176–1187. Springer, 2020.
- CARDOSO, D. O., CARVALHO, D. S., ALVES, D. S., et al. “Financial credit analysis via a clustering weightless neural classifier”, *Neurocomputing*, v. 183, pp. 70–78, 2016.
- NEUMANN, L., GUIMARÃES, A., ARANHA, D. F., et al. “Homomorphic WiSARDs: Efficient Weightless Neural Network training over encrypted data”, *arXiv preprint arXiv:2403.20190*, 2024.
- CARDOSO, D. D. O., GAMA, J., DE GREGORIO, M., et al. “Wips: the wisard indoor positioning system”, 2013.
- SOUZA, C., NOBRE, F., LIMA, P. M., et al. “Recognition of HIV-1 subtypes and antiretroviral drug resistance using weightless neural networks.” In: *ESANN*, v. 12, pp. 429–434, 2012.
- BARBOSA, R., CARDOSO, D. O., CARVALHO, D., et al. “Weightless neuro-symbolic GPS trajectory classification”, *Neurocomputing*, v. 298, pp. 100–108, 2018.
- RANGEL, F., FIRMINO, F., ALVES, S., et al. “Aplicando Redes Neurais sem Peso em Mineração de Opinião no Twitter”, 2021.

- DA SILVA MOREIRA, R., EBECKEN, N. F. F. “APLICAÇÃO DA REDE NEURAL SEM PESO WISARD PARA O RASTREAMENTO DE ALVOS DE SUPERFÍCIE NO MAR”, 2013.
- BADUE, C., PEDRONI, F., DE SOUZA, A. F. “Multi-label text categorization using VG-RAM weightless neural networks”. In: *2008 10th Brazilian Symposium on Neural Networks*, pp. 105–110. IEEE, 2008.
- YORK, T., DUGGAN, P. “Processing of tomographic data using weightless neural networks”, *Journal of Intelligent Systems*, v. 7, n. 3-4, pp. 349–366, 1997.
- COTTA, K. P. “Aplicação de rede neural sem peso e locality-sensitive hashing para o problema de cold-start item em filtragem colaborativa”, 2018.
- SRIDHARAN, N. V., JOSEPH, J. V., VAITHIYANATHAN, S., et al. “Weightless neural network-based detection and diagnosis of visual faults in photovoltaic modules”, *Energies*, v. 16, n. 15, pp. 5824, 2023.
- MAHESH, B. “Machine learning algorithms-a review”, *International Journal of Science and Research (IJSR)*.*[Internet]*, v. 9, n. 1, pp. 381–386, 2020.
- HOI, S. C., SAHOO, D., LU, J., et al. “Online learning: A comprehensive survey”, *Neurocomputing*, v. 459, pp. 249–289, 2021.
- CACCIARELLI, D., KULAHCI, M. “Active learning for data streams: a survey”, *Machine Learning*, v. 113, n. 1, pp. 185–239, 2024.
- CUNERAY, K., AKCAM, N., OKAN, T., et al. “28/38 GHz dual-band MIMO antenna with wideband and high gain properties for 5G applications”, *AEU-International Journal of Electronics and Communications*, v. 162, pp. 154553, 2023.
- KLAUTAU, A., BATISTA, P., GONZÁLEZ-PRELCIC, N., et al. “5G MIMO data for machine learning: Application to beam-selection using deep learning”. In: *2018 Information Theory and Applications Workshop (ITA)*, pp. 1–9. IEEE, 2018.
- LI, X., ALKHATEEB, A. “Deep learning for direct hybrid precoding in millimeter wave massive MIMO systems”. In: *2019 53rd Asilomar Conference on Signals, Systems, and Computers*, pp. 800–805. IEEE, 2019.
- XU, W., GAO, F., JIN, S., et al. “3D scene-based beam selection for mmWave communications”, *IEEE Wireless Communications Letters*, v. 9, n. 11, pp. 1850–1854, 2020.

- GUI, J., LIU, Y., DENG, X., et al. “Network Capacity Optimization for Cellular-Assisted Vehicular Systems by Online Learning-Based mmWave Beam Selection”, *Wireless Communications and Mobile Computing*, v. 2021, n. 1, pp. 8876186, 2021.
- NGUYEN, T. T., NGUYEN, K.-K. “A deep learning framework for beam selection and power control in massive MIMO-millimeter-wave communications”, *IEEE Transactions on Mobile Computing*, v. 22, n. 8, pp. 4374–4387, 2022.
- COUSIK, T. S., SHAH, V. K., ERPEK, T., et al. “Deep learning for fast and reliable initial access in AI-driven 6G mm wave networks”, *IEEE Transactions on Network Science and Engineering*, 2022.
- GONZÁLEZ-PRELCIC, N., MÉNDEZ-RIAL, R., HEATH, R. W. “Radar aided beam alignment in mmWave V2I communications supporting antenna diversity”. In: *2016 Information Theory and Applications Workshop (ITA)*, pp. 1–7. IEEE, 2016.
- CHATZOGLOU, E., GOUDOS, S. K. “Beam-Selection for 5G/B5G Networks Using Machine Learning: A Comparative Study”, *Sensors*, v. 23, n. 6, pp. 2967, 2023.
- REUS-MUNS, G., SALEHI, B., ROY, D., et al. “Deep learning on visual and location data for V2I mmWave beamforming”. In: *2021 17th International Conference on Mobility, Sensing and Networking (MSN)*, pp. 559–566. IEEE, 2021.
- GUPTA, S., SAXENA, N., ROY, A., et al. “Efficient mmWave Beam Selection using ViTs and GVEC: GPS-based Virtual Environment Capture”. In: *2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, pp. 1–6. IEEE, 2023.
- CHEN, Z., LIU, M., ZHAO, H., et al. “Enhancing LIDAR-based mm Wave Beam Selection with AugMix Augmented CNNs”. In: *2023 IEEE 23rd International Conference on Communication Technology (ICCT)*, pp. 926–930. IEEE, 2023.
- KLAUTAU, A., GONZÁLEZ-PRELCIC, N., HEATH, R. W. “LIDAR data for deep learning-based mmWave beam-selection”, *IEEE Wireless Communications Letters*, v. 8, n. 3, pp. 909–912, 2019.

- MASHHADI, M. B., JANKOWSKI, M., TUNG, T.-Y., et al. “Federated mmWave beam selection utilizing LIDAR data”, *IEEE Wireless Communications Letters*, v. 10, n. 10, pp. 2269–2273, 2021.
- KLAUTAU, A., DE OLIVEIRA, A., TRINDADE, I. P., et al. “Generating MIMO channels for 6G virtual worlds using ray-tracing simulations”. In: *2021 IEEE Statistical Signal Processing Workshop (SSP)*, pp. 595–599. IEEE, 2021.
- MANJARRES, J. C., CARDOSO, D. O., KLAUTAU, A., et al. “A WiSARD Network Approach for 5G MIMO Beam Selection”. In: *International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems*, pp. 360–373. Springer, 2024.
- ZHENG, Y., CHEN, S., ZHAO, R. “A deep learning-based mmWave beam selection framework by using lidar data”. In: *2021 33rd Chinese Control and Decision Conference (CCDC)*, pp. 915–920. IEEE, 2021.
- DIAS, M., KLAUTAU, A., GONZÁLEZ-PRELCIC, N., et al. “Position and LIDAR-aided mmWave beam selection using deep learning”. In: *2019 IEEE 20th International Workshop on Signal Processing Advances in Wireless Communications (SPAWC)*, pp. 1–5. IEEE, 2019.
- ZECCHIN, M., MASHHADI, M. B., JANKOWSKI, M., et al. “LIDAR and position-aided mmWave beam selection with non-local CNNs and curriculum training”, *IEEE Transactions on Vehicular Technology*, v. 71, n. 3, pp. 2979–2990, 2022.
- MAKSYMOVA, I., STEGER, C., DRUML, N. “Review of lidar sensor data acquisition and compression for automotive applications”, *Multidisciplinary Digital Publishing Institute Proceedings*, v. 2, n. 13, pp. 852, 2018.
- RAJ, T., HASHIM, F. H., HUDDIN, A. B., et al. “A survey on LiDAR scanning mechanisms”, *Electronics*, v. 9, n. 5, pp. 741, 2020.

Apêndice A

Antenas Uniformes Planares (UPA)

Os array planares possuem configurações de antenas dispostas em uma grade retangular bidimensional. Eles são amplamente utilizados em sistemas MIMO (Multiple Input Multiple Output) devido à sua capacidade de explorar a dimensão espacial tanto no plano horizontal quanto no vertical.

Os elementos do UPA são dispostos em uma matriz com N_X elementos em cada linha e N_Y elementos em cada coluna, formando um total de $N = N_x \cdot N_y$. A separação entre elementos é geralmente uniforme ($d_x \times d_y$). Arrays planares podem formar feixes tanto no plano azimutal (360) quanto no plano de elevação (180), permitindo um controle mais refinado da direcionalidade dos sinais. O vetor de direção de um UPA depende dos ângulos de chegada (AoA) ou partida (AoD) definidos por (θ, ϕ) .

O vetor de direção do receptor para um angulo de chegada $\theta = (\theta_{AoA}, \phi_{AoA})$ onde θ_{AoA} é o angulo de elevação e ϕ_{AoA} de azimute é definido como:

$$\mathbf{a}_R(\theta) = \frac{1}{\sqrt{N_R}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}u_1d_R} \\ e^{j\frac{2\pi}{\lambda}u_2d_R} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}u_{N_R-1}d_R} \end{bmatrix},$$

onde u_n é a fase relativa do n -ésimo elemento do array, definida em função da posição (n_x, n_y) do elemento n no plano e dos ângulos de chegada θ_{AoA} (elevação) e ϕ_{AoA} (azimute):

$$u_n = n_x \sin(\theta_{AoA}) \cos(\phi_{AoA}) + n_y \sin(\theta_{AoA}) \sin(\phi_{AoA}),$$

com:

$$n_x \in \{0, 1, \dots, N_{R_x} - 1\},$$

$$n_y \in \{0, 1, \dots, N_{R_y} - 1\}.$$

Expandindo o vetor de direção:

$$\mathbf{a}_R(\theta) = \frac{1}{\sqrt{N_R}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}d_R(0\cdot\sin(\theta_{AoA})\cos(\phi_{AoA})+1\cdot\sin(\theta_{AoA})\sin(\phi_{AoA}))} \\ e^{j\frac{2\pi}{\lambda}d_R(1\cdot\sin(\theta_{AoA})\cos(\phi_{AoA})+0\cdot\sin(\theta_{AoA})\sin(\phi_{AoA}))} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}d_R((N_{Rx}-1)\cdot\sin(\theta_{AoA})\cos(\phi_{AoA})+(N_{Ry}-1)\cdot\sin(\theta_{AoA})\sin(\phi_{AoA}))} \end{bmatrix}.$$

O vetor de direção do transmissor em função do ângulo de partida $\theta = (\theta_{AoD}, \phi_{AoD})$ é definido como:

$$\mathbf{a}_T(\theta) = \frac{1}{\sqrt{N_T}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}v_1d_T} \\ e^{j\frac{2\pi}{\lambda}v_2d_T} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}v_{N_T-1}d_T} \end{bmatrix},$$

onde v_n é a fase relativa do n -ésimo elemento do array, definida em função da posição (m_x, m_y) do elemento n no plano e dos ângulos de partida θ_{AoD} (elevação) e ϕ_{AoD} (azimute):

$$v_n = m_x \sin(\theta_{AoD}) \cos(\phi_{AoD}) + m_y \sin(\theta_{AoD}) \sin(\phi_{AoD}),$$

com:

$$m_x \in \{0, 1, \dots, N_{Tx} - 1\},$$

$$m_y \in \{0, 1, \dots, N_{Ty} - 1\}.$$

Expandindo o vetor de direção do transmissor:

$$\mathbf{a}_T(\theta) = \frac{1}{\sqrt{N_T}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}d_T(0\cdot\sin(\theta_{AoD})\cos(\phi_{AoD})+1\cdot\sin(\theta_{AoD})\sin(\phi_{AoD}))} \\ e^{j\frac{2\pi}{\lambda}d_T(1\cdot\sin(\theta_{AoD})\cos(\phi_{AoD})+0\cdot\sin(\theta_{AoD})\sin(\phi_{AoD}))} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}d_T((N_{Tx}-1)\cdot\sin(\theta_{AoD})\cos(\phi_{AoD})+(N_{Ty}-1)\cdot\sin(\theta_{AoD})\sin(\phi_{AoD}))} \end{bmatrix}.$$

Apêndice B

Antenas Uniformes Circulares (UCA)

Arrays circulares, também conhecidos como Uniform Circular Arrays (UCA), são configurações de antenas onde os elementos estão dispostos uniformemente ao longo da circunferência de um círculo. Eles oferecem características específicas que os tornam vantajosos em certos cenários de sistemas MIMO (Multiple Input Multiple Output).

Características e Funcionamento

- **Geometria e Direcionalidade:** Cada elemento do array está localizado em posições angulares específicas $\phi_k = \frac{2\pi k}{N}$, onde $k = 0, 1, \dots, N - 1$. A disposição circular permite cobrir uniformemente todas as direções no plano azimutal (360°).
- **Resposta de Direção:** A resposta de direção de um UCA depende do ângulo de chegada (AoA) ou de partida (AoD), permitindo uma detecção e transmissão mais eficientes em múltiplas direções.
- **Vantagens no Processamento de Sinais:** Ao contrário dos arrays lineares, UCAs não apresentam lacunas de cobertura em certas direções. A separação angular mais uniforme melhora a resolução espacial, facilitando a distinção entre sinais provenientes de diferentes direções. UCAs são amplamente usados em algoritmos de localização e rastreamento de dispositivos devido à sua capacidade de estimar com alta precisão os ângulos de chegada e partida.

Para um array de antenas circular com N elementos igualmente espaçados ao longo de um círculo de raio r , o vetor de direção pode ser formulado com base no ângulo de chegada ou partida $\theta = (\theta_{AoA}, \phi_{AoA})$

O vetor de direção para um array circular uniforme (UCA) é definido como:

$$\mathbf{a}(\theta) = \frac{1}{\sqrt{N}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_1 - \phi_{AoA}) \sin(\theta_{AoA})} \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_2 - \phi_{AoA}) \sin(\theta_{AoA})} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_{N-1} - \phi_{AoA}) \sin(\theta_{AoA})} \end{bmatrix},$$

onde:

$$\phi_k = \frac{2\pi k}{N}, \quad k = 0, 1, \dots, N-1,$$

ϕ_{AoA} = ângulo de azimuth do sinal incidente,

θ_{AoA} = ângulo de elevação do sinal incidente,

r = raio do círculo do array,

λ = comprimento de onda do sinal.

Para o caso de transmissão ($\theta = (\theta_{AoD}, \phi_{AoD})$), o vetor de direção pode ser formulado de maneira análoga:

$$\mathbf{a}_T(\theta) = \frac{1}{\sqrt{N}} \begin{bmatrix} 1 \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_1 - \phi_{AoD}) \sin(\theta_{AoD})} \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_2 - \phi_{AoD}) \sin(\theta_{AoD})} \\ \vdots \\ e^{j\frac{2\pi}{\lambda}r \cos(\phi_{N-1} - \phi_{AoD}) \sin(\theta_{AoD})} \end{bmatrix}.$$

A resposta de direção de um UCA depende do ângulo de chegada (AoA) ou de partida (AoD), permitindo uma detecção e transmissão mais eficientes em múltiplas direções.

Apêndice C

Ajuste de Hiper-parâmetros da rede WiSARD usando coordenadas

Ao usar dados de GPS como entrada, as coordenadas são binarizadas usando a abordagem do termômetro. A resolução do termômetro não apenas define a precisão dos dados de entrada, mas também determina o tamanho da entrada para cada coordenada, conforme detalhado na Tabela C.1.

Resolução	Tamanho da entrada	
	x	y
1	20	245
2	40	490
4	80	980
8	160	1.960
16	320	3.920
32	640	7.840
64	1.280	31.360
128	2.560	62.720
256	5.120	31.360
512	10.240	125.440

Tabela C.1: Impacto da resolução do termômetro sobre o tamanho da entrada

Além disso, a precisão do modelo é significativamente influenciada pela resolução do termômetro e pelo tamanho do endereçamento da memória. Essa relação é representada graficamente na Figura C.1, a qual apresenta um mapa de calor do desempenho do WiSARD em diferentes configurações. Adicionalmente, a Figura C.2 ilustra o desempenho ao longo de uma linha específica do mapa de calor, correspondendo a uma resolução de termômetro de 8. Com base nos resultados dessa análise, foram selecionados os parâmetros que alcançou a maior acurácia, resolução de termômetro igual a 16 e tamanho do endereçamento da memória 54 como os valores ótimos para as avaliações futuras.




Figura C.1: Mapa de calor do desempenho da acurácia com entradas de coordenadas da rede WiSARD




Figura C.2: Desempenho da rede WiSARD variando o endereçamento da memória com entradas de coordenadas e resolução igual 8

Apêndice D

Análise do *dataset* Raymobtime

Na seleção de feixe é possível notar uma dependência do feixe com relação a posição do receptor e ao tipo de conexão, podendo ser esta com LoS ou NLoS. Na figura D.1, é apresentado o feixe selecionado dentre os 256 possíveis para realizar a conexão de cada par Tx/Rx.

Para observar com detalhes as clusterizações de feixes, foi separado os feixes usados pelo transmissor e pelo receptor, como mostrado na figura D.2

No entanto, de acordo com a fundamentação teórica, a seleção dos índices dos feixes sofrem grandes mudanças devido ao tipo de comunicação estabelecida, sendo esta LOS ou NLOS, na Figura D.3 podemos observar este fenômeno no lado transmissor e na figura D.4 do lado do receptor

Com o intuito de analisar detalhadamente o comportamento do feixes, do lado do receptor o qual foi configurado com 8 elementos de antenas, a figura D.5a apresenta uma clara escolha de feixes quando se trata de um canal de comunicacao LOS, o que nao acontece na figura D.5b quando uma canal de comunicacao NLOS é usado.






Figura D.1: Feixes selecionados em cada canal de comunicação para todos os receptores




(a) feixes usados no Tx




(b) feixes usados no Rx

Figura D.2: Segregação dos feixes selecionados entre o Tx e o RX




(a) comunicação LOS




(b) comunicação NLOS

Figura D.3: Seleção de feixes no Transmissor




(a) comunicação LOS




(b) comunicação NLOS

Figura D.4: Seleção de feixes no Receptor



(a) comunicação LOS



(b) comunicação NLOS

Figura D.5: Seleção de feixes no Receptor